

## 凸优化视频课程

优化 = 教学规划 (Math Programming)

分类方法

线性规划 LP / 非线性

单纯形法 解决 LP

对 LP:

是 feasible set

↑ 是和下降方向 (梯度反方向)

凸规划 / 非凸规划

所有  $f$  都是凸函数

$f$  是凸集

$C = \mathbb{R}$

凸规划一定可以在多项式时间中得到求解 (但单纯形法不一定可以), 现在的 '内点法' 是最主要方法


证明

从射集到射组合:

有射集  $x_1, x_2, x_3 \in C$ ,  $\theta_1 + \theta_2 + \theta_3 = 1$

有  $\frac{\theta_1}{\theta_1 + \theta_2} x_1 + \frac{\theta_2}{\theta_1 + \theta_2} x_2$  在  $C$  内 (射集定义)

又有  $\frac{\theta_1}{\theta_1 + \theta_2} (\frac{\theta_1}{\theta_1 + \theta_2} x_1 + \frac{\theta_2}{\theta_1 + \theta_2} x_2) + \theta_3 x_3$  也在  $C$  内  
 $= \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$  也在  $C$  内



$\mathcal{F}$

$$x_2 = -x_1$$

有一类伪集，要求  $\theta_1 + \theta_2 = 1$ ：

$$V = C - x_0 = \{x - x_0 \mid x \in C\} \quad \forall x_0 \in C$$

(是 - 一个  $\theta_1 + \theta_2 = 1$  的伪集)

V 是与 C 相关的子空间 L 只有 C 是伪集，才是它是子空间)

这个 V 既是  $\alpha + \beta \neq 1$ , 但  $\alpha x_1 + \beta x_2 \in V$

同时包括  $\alpha + \beta = 1$   $\therefore V$  伪集

证：

$$\forall \alpha V_1, V_2 \in V, \alpha + \beta \in \mathbb{R}$$

$\alpha V_1 + \beta V_2 + x_0$  记属于 C, 即  $\alpha V_1 + \beta V_2$  属于 V

$$\frac{\alpha(V_1 + x_0) + \beta(V_2 + x_0) + (1-\alpha-\beta)x_0}{C}$$

$$\alpha + \beta + (1-\alpha-\beta) = 1$$

$\therefore C \neq V$

从而  $\alpha V_1 + \beta V_2 = C - x_0 \in V$

从性质一般的伪集 C 得到性质更好的伪集 V

V 一定经过原点 (因为从 C 上减掉一个点)

B.12 任何方程的解集是伪集

$$\text{证: } C = \{x \mid Ax = b\}$$

用定义:  $x_1 \in C, x_2 \in C, \theta_1 + \theta_2 = 1$

$$\begin{aligned} & A(\theta_1 x_1 + \theta_2 x_2) \\ &= \theta_1 Ax_1 + \theta_2 Ax_2 = (\theta_1 + \theta_2)b = b \in C \end{aligned}$$

$\therefore L = \{x \mid Ax = b\}$  相关的子空间

$V = C - x_0 \mid x_0$  和是同空间

3

$$= \{x - x_0 \mid A(x - x_0) = 0\} \quad (\text{即代入 } Ax_0 = b)$$


$= \{y \mid Ay = 0\}$   $A$  的化零空间

(反过来也对: 任意仿集可理解为  $\text{Linear function}$  的解集)

例 1. 由集合  $C$ , 构造一个最小仿集集  $\mathcal{C}$

用仿射包来表示  $\text{affine set: } \{ \theta x_1 + \dots + \theta_k x_k \mid x_1, \dots, x_k \in C, \theta_1 + \dots + \theta_k = 1 \}$

假设  $C = \{x_1, x_2\}$



当  $\{x_1, x_2, x_3\}$ , 其仿包是  $\mathbb{R}^2$

这个是直和即  $\{x_1, x_2, x_3\}$  的仿包

凸集 Convex

仿集一定是凸集

凸集概念

$C$  为凸集  $\Leftrightarrow \forall x_i \in C$  的凸组合  $\in C$

凸包

( $\Rightarrow C$  中任意个点的凸组合的全体 = 凸包)



锥 cone 一星锥  $\Leftrightarrow \forall x \in C, \theta x \in C \ (\theta \geq 0)$

凸锥 convex cone 一定是一星凸集:  $(x_1, x_2 \in C, \theta_1, \theta_2 \geq 0, \theta_1 + \theta_2 \leq 1) \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C$

一个

三条射线


三条射线是一个锥 (注意, 锥必须过原点)



这是个锥 (= 3个射线)  
(也是凸锥)

4

向量有凸锥组合和凸锥包



当一个集合  $C = \{x_0\}$  有一个点时,

$\theta_1 x_0 + \theta_2 x_0 = (\theta_1 + \theta_2) x_0 = x_0 \therefore A \subset C$  是仿, 凸, 凸锥,

$\theta_1 x_0 \neq x_0 \therefore$  不是锥

(只有当  $x_0$  原点时才是锥, 且是凸锥)

当集合  $C = \emptyset$ ,

$C$  是仿, 凸, 凸锥


几种重要的凸集

	仿集	凸	凸锥
1维空间	✓	✓	✓
$n$ 维空间的子空间	✓	✓	✓
任意直线	✓	✓	半空间 (过原点) ✓
线段	X (只有有限时)	✓	X (只有限时)

超平面 hyperplane

$\{x | a^T x = b\} (a \neq 0)$  被称为超平面

举一



5

	仿	凸	凸鏡
超平面	✓	✓	半空(✓過原點的空)
半空間	X	✓	子空(✓過原點)

球形半指球(歐式空間中)

$$B = B(x_c, r) = \{x \mid \|x - x_c\|_2 \leq r\}$$

球  $\overline{\text{圓盤}}(r=0時)$  ✓ 可能

用定義驗證

$$\forall x_1, x_2 \in B, \text{ 那 } \|x_1 - x_c\|_2 \leq r, \|x_2 - x_c\|_2 \leq r$$

$$\forall \theta \in [0, 1]$$

$$\text{証 } \|\theta x_1 + (1-\theta)x_2 - x_c\|_2 \leq r$$

$$\begin{aligned} & \|\theta(x_1 - x_c) + (1-\theta)(x_2 - x_c)\|_2 \\ & \leq \|\theta(x_1 - x_c)\|_2 + \|(1-\theta)(x_2 - x_c)\|_2 \quad (\text{三角不等式}) \\ & = r \end{aligned}$$

∴得證

6/55

椭球

加权的L2范数

$$E(x_c, P) = \{x \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1, P \in S^n_+$$

椭球的半轴由P的奇异值决定

$$\text{例: } x^T \begin{pmatrix} 4 & 0 \\ 0 & 1 \end{pmatrix}^{-1} x \leq 1$$

$$\Rightarrow \text{singular} = 2, 1 \quad (\text{特征值}) \quad \Rightarrow \text{Eigenvalue} = \sqrt{\text{Eigenvalue}(A^T A)}$$

奇异值和特征值不一样

线性

$$P = \{x \mid a_j^T x \leq b_j, c_i^T x = d_j\} \quad (\text{每个子集一个半空间/超平面})$$

最优化

6

## 单纯形


$\mathbb{R}^n$  空间中选择  $v_0, \dots, v_k$  共  $k+1$  个点,  $v_i - v_0, \dots, v_k - v_0$  线性无关,

则与上述点相似的单纯形  $\gamma$

$$\gamma = \text{Conv} \{v_0, \dots, v_k\} = \{\theta_0 v_0 + \dots + \theta_k v_k \mid \theta \geq 0, \theta^T \theta = 1\}$$


即基于这些点构造出的凸包

例: 取  $k=1$



$v_i - v_0$  线性无关

$k=2$



在  $\mathbb{R}^2$  中,  $k$  无法再变大

↳ simplex 是多面体

思考: 给一个 simplex, 一元可以写成多面体

定义:  $y = [\theta_0, \dots, \theta_k]^T$ , 有  $y \geq 0, I^T y \leq 1$  (因为  $y^T e = 1$ )

$$B = [v_i - v_0, \dots, v_k - v_0] \in \mathbb{R}^{n \times k}$$

将  $x$  表成  $x =$  (  $x$  是 simplex)

$$x = v_0 + \theta_1(v_1 - v_0) + \dots + \theta_k(v_k - v_0)$$

$$x = v_0 + \cancel{y} B y$$

$\because \text{rank}(B) = k$  (因为  $k$  个线性无关)

$B$  相关的性质可得  $\begin{bmatrix} I^k \\ 0 \end{bmatrix} \in \mathbb{C}^{n \times (k+1)}$

$$(A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \text{ 非奇异}, \text{ 使 } AB = \begin{bmatrix} I^k \\ 0 \end{bmatrix}, \text{ 且 } B^{-1} = \frac{1}{\det B} I)$$

$$\Rightarrow Ax = Av_0 + Ab y \quad (Ab \text{ 奇异})$$

$$\begin{bmatrix} A_1 \\ A_2 \end{bmatrix} x = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} v_0 + \begin{bmatrix} A_1 B \\ A_2 B \end{bmatrix} y$$

$$\Rightarrow \begin{cases} A_1 x = A_1 v_0 + (A_1 B) y \\ A_2 x = A_2 v_0 + (A_2 B) y \end{cases}$$

$$\Rightarrow \begin{cases} A_1 x \geq A_1 v_0 \\ 1 \cdot A_1 x \leq 1 + 1^T A_1 v_0 \\ A_2 x = A_2 v_0 \end{cases} \quad (0 \leq y \leq 1)$$

即任意点由线性不等式和等式描述，即多面体 (30:40)

(一个无法想象的凸集)

$$S^n = \{x \in \mathbb{R}^{n \times n} \mid x = x^T\} \quad S_+^n = \{x \in \mathbb{R}^{n \times n} \mid x = x^T, x \geq 0\}$$

$$S_{++}^n = \{x \in \mathbb{R}^{n \times n} \mid x = x^T, x > 0\}$$

~~都是凸锥~~

$$S_+^n \text{ 为 } \forall \theta_1, \theta_2 \geq 0, \forall A, B \in S_+, \exists \theta_1 A + \theta_2 B \in S_+^n$$

~~是凸锥~~ 易得  $\theta_1 A + \theta_2 B$  也是对称

矩阵  $A$  具性质  $\forall x \in \mathbb{R}^n, x^T A x \geq 0$ , 则  $A \in S_+^n$

$x^T (\theta_1 A + \theta_2 B) x \geq 0$  易得 ~~是凸锥~~

但  $S_{++}^n$  不是凸锥 (因为  $\theta_1 = 0, \theta_2 = 0$  导致  $0$  不在  $S_{++}^n$  中), 但是凸集

举例  $n=1, S_+^1 = x \geq 0$

$S_{++}^1 = x > 0$  不包含原点, 那是~~是~~锥

$$n=2 \quad S_+^2 = \left\{ \begin{pmatrix} x \\ y \end{pmatrix} \mid x \geq 0, y \geq 0, x^2 \geq y^2 \right\}$$

保凸运算

① 空集

② 仿射函数  $f(x) = Ax + b$

即缩小与位移保持凸性

逆映射也保凸 (因为还是线性)


③ 两个凸集的合 (不是并集)

$$S_1 + S_2 = \{x+y \mid x \in S_1, y \in S_2\}$$

用仿射:  $S_1 \times S_2 = \{(x_1, y) \mid x \in S_1, y \in S_2\}$  也凸

$$f(x_1, y) = x_1 + y = (x_1, y) \cdot (1)$$

每一个向量  $\in S_1 \times S_2$ , 是凸集  $S_1 \times S_2$  的仿射, 保凸



8

例：线性矩阵不等式

$$A(x) = x_1 A_1 + \dots + x_n A_n \leq B$$

$B, x_i, A_i \in S^n$

$A(x) - B \leq 0$ , 该矩阵  $A(x) - B$  非负定

解集是凸集

意义仿射变换  $f(x) = B - A(x)$ , 从高维矩阵空间变到低维

$S^n_+$  的凸

$$f^{-1}(S^n_+) = \{x \mid B - A(x) \geq 0\}$$

从低维映射到高维

$f^{-1}$  也是凸的， $\{x \mid B - A(x) \geq 0\}$  得证

例：半椭球是球的仿射映射

$$\{x \mid (x - x_0)^T P^{-1} (x - x_0) \leq 1\}$$

$\{u \mid \|u\|_2 \leq 1\}$  单位球

$$f(u) = P^{\frac{1}{2}}u + x_0 \quad ((P^{\frac{1}{2}}) \cdot (P^{\frac{1}{2}}) = P)$$

↓

$$\{f(u) \mid \|u\|_2 \leq 1\}$$

8/55

$$= \{P^{\frac{1}{2}}u + x_0 \mid \|u\|_2 \leq 1\}$$

$$x \triangleq P^{\frac{1}{2}}u + x_0$$

$$u = P^{-\frac{1}{2}}(x - x_0) \quad (\text{因为 } P \text{ 是 } S^n_+)$$

$$= \{x \mid \|P^{-\frac{1}{2}}(x - x_0)\|_2 \leq 1\}$$

$$= \{x \mid (x - x_0)^T P^{-1} (x - x_0) \leq 1\}$$


9

透视函数 (降维)

→ 2D 的 n 维实数空间

$$P: \mathbb{R}^{n+1} \rightarrow \mathbb{R}^n \quad \text{dom } P = \mathbb{R}^n \times \mathbb{R}_{++}$$

$$P(z, t) = \frac{z}{t} \quad z \in \mathbb{R}^n, t \in \mathbb{R}_{++}$$

除完之后最后的  $t$  没用了扔掉,  $\mathbb{R}^{n+1} \rightarrow \mathbb{R}^n$ 

凸集透视后仍是凸集

例：考虑  $\mathbb{R}^{n+1}$  线段,  $x = (\bar{x}, x_{n+1})$ ,  $y = (\bar{y}, y_{n+1})$ 

$$\theta x + (1-\theta)y \in \theta \mathbb{R}[0, 1]$$

↓ 变换后的凸且仍为线段

(0, u) 与  $\bar{x}$  对应

$$x \mapsto P(x), \quad y \mapsto P(y)$$

$$P(\theta x + (1-\theta)y) = \frac{\theta \bar{x} + (1-\theta)\bar{y}}{\theta x_{n+1} + (1-\theta)y_{n+1}}$$

$$= \underbrace{(\theta \cdot x_{n+1})^{-1}}_{\sim} \cdot \frac{\bar{x}}{x_{n+1}} + \underbrace{(1-\theta) y_{n+1}}_{\sim} \cdot \frac{\bar{y}}{y_{n+1}} \quad (\forall \theta \in [0, 1])$$

$$= u \cdot P(x) + (1-u) \cdot P(y)$$

 $0$  与  $u = 0$  对应二点  $\leftrightarrow$  该透视后仍线性透视  $\leftrightarrow$  对应

透视函数的反函数.

保凸

$$P \subset \mathbb{R}^n$$

$$\text{定义 } P^{-1}(C) = \{x, t) \in \mathbb{R}^{n+1} \mid \frac{x}{t} \in C, t > 0\}$$

若  $(x, t), (y, s) \in P^{-1}(C)$

$\frac{\theta x + (1-\theta)y}{\theta t + (1-\theta)s}$  仍属于  $C$

$$= \frac{\theta t}{\theta t + (1-\theta)s} \frac{x}{t} + \frac{(1-\theta)s}{\theta t + (1-\theta)s} \frac{y}{s} \in C$$

(因为  $C$  是凸集)

得证

线性形式函数

(把一个点先放映，再透视)

$g(x)$  是例放映

$$g(x) = [A]x + [b]$$

$$P: \mathbb{R}^{n+1} \rightarrow \mathbb{R}^m$$

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m \stackrel{\Delta}{=} P \circ g$$

$$f = \frac{Ax+b}{Cx+d}$$

(写成  $Cx+d > 0$ )

保凸 (因为经过两次放大变换)

(虽然看起来非常非线性，但实际很软，凸)

例：两个随机变量的联合分布  $\rightarrow$  条件概率

$$u \in \{1, \dots, n\}, v \in \{1, \dots, m\}$$

$$f_{ij} = P(u=i | v=j)$$

$$f_{ij} = \frac{P_{ij}}{\sum P_{ik}}$$

是一个线性形式

$$P_{ij} = (0, \dots, 0, 1, \dots, 0) \cdot \begin{pmatrix} i \\ p_{ij} \end{pmatrix}$$

解联立矩阵是高斯：

9/55 缺失 (凸函数的定义)

10/55 凸函数的拓展

$$\tilde{f} = \begin{cases} f(x), & x \in \text{dom } f \\ +\infty, & x \notin \text{dom } f \end{cases} \Rightarrow \text{dom } \tilde{f} = \mathbb{R}^n$$

子集  $\text{dom } f$  上  
定义的子集满足  $\leq \infty$

(凸集)


例：凸函数是凸函数 (图示，图中凸)

$$f(x) = \begin{cases} \text{无理数} & x \in C \\ 0 & x \notin C \end{cases} \Rightarrow f(x) = \begin{cases} 0 & x \in C \\ \infty & x \notin C \end{cases} (\in \mathbb{R})$$

一阶条件：(蕴含： $\text{dom } f$  是开集，则在端点不可微)

当  $f$  可微时， $\exists x, y \in \text{dom } f$ ，有

$$f(y) \geq f(x) + \nabla f(x) \cdot (y-x) \quad (\text{且 } \text{dom } f \text{ 凸})$$



(定义是从 V 的上面去理解)

根据一阶条件，当找到  $x$  使  $\nabla f(x)=0$ ，则  $f(y) \geq f(x) \Rightarrow y \min$

一阶条件 (部分)

① 考虑一维：

$$\text{若 } f(y) \geq f(x) + \nabla f(x)(y-x)$$

$\Rightarrow$

已知  $f$  为上

且  $t \in (0, 1)$

$$x+t(y-x) \in \text{dom } f$$

12

$$f(x+t(y-x)) \leq (1-t)f(x) + t f(y)$$

$$t f(y) \geq t f(x) + f(x+t(y-x)) - f(x)$$

$$f(y) \geq f(x) + \frac{f(x+t(y-x)) - f(x)}{t}$$

极限  $t \rightarrow 0^+$

$$f(y) \geq f(x) + \lim_{t \rightarrow 0^+} \frac{f(x+t(y-x)) - f(x)}{t}$$

∴ 得证

$\therefore$   $\leq$

设  $x \neq y, x, y \in \text{dom } f, \theta \in [0, 1]$

$$\therefore z = \theta x + (1-\theta)y$$

$$(f(x)) \geq f(z) + f'(z)(x-z) \quad (x \neq z)$$

$$(f(y)) \geq f(z) + f'(z)(y-z) \quad (y \neq z)$$

$$\theta f(x) + (1-\theta)f(y) \geq f(z) + \theta f'(z)x + (1-\theta)f'(z)y$$

$$= f(z) + (\theta x + (1-\theta)y - z) f'(z)$$

$$= f(z) + \theta f'(z)x + (1-\theta)f'(z)y$$

∴ 得证

11/55 (9月份一个家政)

$\forall x \in \text{dom } f, \text{vector } p$

- 一个向量

$$g(t) = f(x + t(p))$$

将高维降到低维

一阶条件  $n > 1$  的证明

$$g(t) = f(y + (1-t)x)$$

$$= f(x + t(y-x))$$

B

$$g(t) = \nabla f^T(ty + (1-t)x)(y-x)$$

$\because g(t)$  为 (用尽性 & 之 g 中)

$\therefore g(t)$  满足

$$g(t_1) \geq g(0) + \nabla f^T g(t_2) (t_1 - t_2) \quad (\text{-维已证过})$$

$$t_1=1, t_2=0$$

$$g(1) \geq g(0) + \nabla f^T g(0)$$

$$g(1) = f(y), g(0) = f(x)$$

$$f(y) \geq f(x) + \nabla f^T(x)(y-x)$$

从一阶证得  $\Leftarrow$

$$\forall x, y \in \text{dom } f$$

$$t y + (1-t)x \in \text{dom } f, \quad \tilde{t} y + (1-\tilde{t})x \in \text{dom } f'$$

$$f(ty + (1-t)x) \geq f(\tilde{t}y + (1-\tilde{t})x) +$$

$$\nabla f^T(\tilde{t}y + (1-\tilde{t})x)(ty + (1-t)x - \tilde{t}y - (1-\tilde{t})x)$$

(即陷入一阶条件)

$$= (y-x)(t-\tilde{t})$$

$$\text{定义 } g(t) = f(ty + (1-t)x), g(\tilde{t}) = f(\tilde{t}y + (1-\tilde{t})x)$$

$$\therefore g(t) \geq g(\tilde{t}) + \nabla g(\tilde{t})(t-\tilde{t})$$

$$(\text{因为 } g(\tilde{t}) = \nabla f^T(\tilde{t}y + (1-\tilde{t})x)(y-x))$$

$\therefore g$  是凸函数 (定义)

根据 n 的高维意义

$\therefore f$  是凸

二阶条件

(Hessian 矩阵非负)

若二阶可微

$\nabla^2 f(x) \succ 0$  (最实用的)

$n=1$  时

即 P- 阶偏导函数值单调不减 (即  $f$  带着偏个尾)

14

若  $\nabla^2 f > 0$ , 平滑凸

但平滑凸不需要  $\nabla^2 f > 0$

$$\text{例 } f = x^4 \quad \cup$$

$$f' = 4x^3 \quad f'' = 12x^2$$

$$\text{在 } x=0 \text{ 处 } f''=0$$

例一个重要的凸函数

$\Rightarrow$  次函数

$$f(x) = \frac{1}{2} x^T p x + q^T x + r \quad P \in S^n \rightarrow Q \in R^n, \quad r \in R$$

$\Rightarrow$  特性条件

$$\nabla^2 f(x) \text{ 或 } \nabla^2 f(x) = P$$

二次函数  $\nabla^2 f > 0 \Leftrightarrow$  平滑凸

$$\text{例 } f(x) = \frac{1}{x^2}$$

$$\nabla^2 f \quad f'(x) = -2/x^3 \quad f''(x) = 6x^{-4} = \frac{6}{x^4}$$

但是  $\text{dom } f = \{x | x \neq 0\}$ , 不是凸集

∴ 不是凸函数 (但是单独  $x > 0$  or  $x < 0$  是)

例题:  $\nabla^2 f(x) = 0$  阵阵  $\geq 0$

155

$$f(x) = e^{ax} \quad \square$$

$$\nabla^2 f = a^2 e^{ax} \geq 0$$

幂 ( $x > 0$ )  $f = x^a$


$$f'(x) = a x^{a-1}$$

$$f'' = a \cdot (a-1) x^{a-2}$$

$$f'' \geq 0 \quad (a > 1, a \leq 0)$$

$$f'' \leq 0 \quad (0 \leq a \leq 1)$$

也幂之取凸又凹



$$|x|^p$$

$$x < 0$$

$$(-x)^p$$

15.

### 绝对值的幂函数

$$f = |x|^p \quad (x \in R)$$

(由于  $f$  在一旁二阶可微)

$$f' = \begin{cases} px^{p-1} & (x > 0) \\ -p(-x)^{p-1} & (x < 0) \end{cases}$$


$$f'' = \begin{cases} p(p-1)x^{p-2} & (x > 0) \\ p(p-1)(-x)^{p-2} & (x < 0) \end{cases}$$

$p > 1$  时  $f'' > 0$ ,  $\Rightarrow$  凸  $p < 1$  时  $f'' < 0$ ,  $\Rightarrow$  凹

$p > 1$  ( $p \neq 1$ , 因为  $p=1$  不可导)  $\left\{ \begin{array}{l} p \geq 2 \text{ 时 } f'' \geq 0, \text{ 有界} \\ p \in (1, 2) \text{ 时, 复杂, 但仍凸} \end{array} \right.$

$p=1$   $\vee$  也  $\Rightarrow$

$$p = \frac{1}{2}$$



(在  $p \geq 1$  时无角, 弯曲)

### 对数函数 $f = \lg x \quad (x \in R_+)$

凹函数

$$f' = \frac{1}{x} \quad f'' = -\frac{1}{x^2} < 0$$

互换

负熵  $f(x) = x \lg x, \quad x \in R_+$

$$f' = \lg x + 1 \quad f'' = -\frac{1}{x} > 0 \quad \text{严格凸}$$

( $\lg x \leq 0$ ,  $x \uparrow$ ,  $x$  越大  $\lg x$  越来越小)

极小化负熵 = 极大化负熵 (负熵凸+, 容易)

范数  $P(x)$

$$\text{三性质} \quad ① P(ax) = |a|P(x)$$

$$② P(x+y) \leq P(x) + P(y)$$

$$③ P(x) = 0 \Leftrightarrow x = 0$$


等式  $\forall x, y \in R^n, \forall 0 < \theta \leq 1$

$$P(\theta x + (1-\theta)y) \leq P(\theta x) + P(1-\theta)y \quad ②$$

$$= \theta P(x) + (1-\theta)P(y) \quad ①$$

零范数 =  $\|x\|_0$ : 非零元素总数  
零范数非凸 (因为不是真的凸)

例:



$$P(ax) \neq |a|P(x)$$

极值函数

$$f(x) = \max \{x_1, \dots, x_n\} \quad x \in \mathbb{R}^n$$

无法求导, 用定义!

$$f(\theta x + (1-\theta)y)$$

$$= \max \{\theta x_1 + (1-\theta)y_1, \dots, \theta x_n + (1-\theta)y_n\}$$

$$\leq \max \{\theta x_1, \dots, \theta x_n\} + \max \{(1-\theta)y_1, \dots, (1-\theta)y_n\}$$

$$= \theta f(x) + (1-\theta) f(y)$$

∴ 凸

极小极大问题

$$\min_{y \in Y} \max_{x \in X} f(x, y)$$

做可导的逼近 (梯度下降逼近)

( $\Rightarrow$  log sum up) (softmax)

$$f(x) = \log \left( e^{x_1} + \dots + e^{x_n} \right) \quad x \in \mathbb{R}^n$$

$\equiv$   $\log$ ,

$$\max_x f(x) \leq \max_x \log$$

$$\frac{\partial f}{\partial x_i} = \frac{e^{x_i}}{e^{x_1} + \dots + e^{x_n}}$$

$$\text{当 } i \neq j \quad \frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{-e^{x_i} e^{x_j}}{(e^{x_1} + \dots + e^{x_n})^2} < 0$$

$$\frac{\partial^2 f}{\partial x_i^2} = \frac{-e^{x_i} e^{x_i} - e^{x_i} e^{x_i} e^{x_i} - \dots - e^{x_n}}{(e^{x_1} + \dots + e^{x_n})^2} > 0$$

$$\text{定义 } \bar{x} = \begin{bmatrix} e^{x_1} \\ \vdots \\ e^{x_n} \end{bmatrix}$$

$$\therefore \frac{\partial f}{\partial x_i \partial x_j} = \frac{-e^{x_i} e^{x_j}}{(1 + e^{x_1} + \dots + e^{x_n})^2}$$

$$\frac{\partial^2 f}{\partial x_i^2} = \frac{-e^{x_i} e^{x_i} - 1 + e^{x_i} (e^{x_1} + \dots + e^{x_n})}{(1 + e^{x_1} + \dots + e^{x_n})^2}$$

B/55

$$H = \frac{1}{(e^{x_1} + \dots + e^{x_n})^2} \begin{bmatrix} -e^{x_1} (e^{x_1} + e^{x_n}) & 0 & \cdots & 0 & -e^{x_1} \\ 0 & e^{x_n} (e^{x_1} + \dots + e^{x_n}) & \cdots & 0 & \vdots [e^{x_1}, \dots, e^{x_n}]^T \end{bmatrix}$$

$$= \frac{1}{(1 + e^{x_1} + \dots + e^{x_n})^2} \left( (1 + e^{x_1} + \dots + e^{x_n}) \left( \text{diag}\{z\} - z z^T \right) \right)$$

半正定：对  $\forall V \in \mathbb{R}^{n \times n}$ ,  $V^T V \geq 0 \Leftrightarrow V^T H V \geq 0$

$$V^T H V = (V^T V) V^T \text{diag}\{z\} V - V^T z z^T V$$

$$= (\sum z_i) (\sum v_i^2 z_i) - (\sum v_i z_i)^2$$

$$\text{定义 } a_i = v_i \sqrt{z_i} \quad b_i = \sqrt{z_i}$$

$$= (b^T b) (a^T a) - (a^T b)^2 \geq 0 \quad (\text{因为 Cauchy-Schwarz 不等式})$$

特征值  $\rightarrow$  三角形

特征向量  $\rightarrow$  相应特征值的线性组合

$\therefore$  softmax 由

## 几何平均

$$f(x) = (x_1 \cdots x_n)^{\frac{1}{n}} \quad x \in \mathbb{R}_+^n$$

凸函数

(-f是凸)

例

行向量的对数

讲的真:  $f(x) = \log \det(x)$   $\text{dom } f = S_{++}^n$  ( $\det(x) > 0$ )

且

$$\det(x) = \prod x_i$$

(把x看成标量,  $f(x) = \log x$  凸  $\therefore f(x)$  可能无界)当  $n > 1$  时

用凸f的高维定义来证

$$\forall z \in S_{++}^n \rightarrow \text{起}$$

$$\forall t \in \mathbb{R} \rightarrow \text{梯度}$$

$$\forall v \in \mathbb{R}^{n \times n} \rightarrow \text{方向}$$

$$z + tv \in S_{++}^n = \text{dom } f, \text{ 且 } v \in S^n$$

$$g(t) = f(z + tv)$$

$$= \log \det(z + tv)$$

$$= \log \det \{z^{\frac{1}{2}} (I + t z^{-\frac{1}{2}} v z^{-\frac{1}{2}}) z^{\frac{1}{2}}\}$$

$$\text{因为 } (\det(AB))^2 = \det(A) \det(B)$$

$$\therefore g(t) = \log \det z^{\frac{1}{2}} + \log \det (I + t z^{-\frac{1}{2}} v z^{-\frac{1}{2}})$$

$$= \log \det z + \sum_i \log (1 + \lambda_i) \leftarrow \text{对称性}$$

$t z^{-\frac{1}{2}} v z^{-\frac{1}{2}}$  对称, 由行向量得

$$Q \Lambda Q^T \quad (QQ^T = I)$$

$$\therefore \det(I + t z^{-\frac{1}{2}} v z^{-\frac{1}{2}})$$

$$= \det(QQ^T + Q \Lambda Q^T)$$

$$= \det(Q(I + \Lambda)Q^T) = \det(QQ^T) \cdot \det(I + \Lambda)$$

$$= \det(\prod (I + \lambda_i))$$

 $\lambda_i \in (-1, 1)$  由对称性

14/55  $\because g(t)$  的凸性同函数  $f(x)$  的凸性

$$g'(t) = \sum \frac{\lambda_i}{1+t\lambda_i} \quad g'' = \sum \frac{-\lambda_i^2}{(1+t\lambda_i)^2} \leq 0$$

$$\therefore f \text{ 为凸} \Rightarrow g \text{ 为凸}$$

证明

非负的米加权和

$$f_1, \dots, f_m \text{ 为凸}, \text{ 则 } F = \sum w_i f_i \text{ 为凸}$$

证: 考虑

①  $F$  的定义域为  $\Omega$ , 必凸

② 用定义得 凸性

↓

变成积分

↓

若  $f(x, y)$  对任意  $y \in A$ ,  $f(x, y)$  为凸,  $f(x, y)$  为凸  
则  $(x, y)$  为凸集 ( $f(x, y)$  不需要是凸)  $\leftarrow$  联合 (2)

设

$w(y) > 0, \forall y \in A$

$$g(x) = \int_{y \in A} w(y) f(x, y) dy \text{ 为凸} \quad (\text{对求和的拓展})$$

仿射映射

$$Ax + b \quad A \in \mathbb{R}^{n \times m} \quad b \in \mathbb{R}^m$$

$$g(x) = f(Ax + b) \quad \text{dom } g = \{x \mid Ax + b \in \text{dom } f\}$$

$$\exists \theta = \sum x_i y_i \in \text{dom } f$$

$$g(\theta x + (1-\theta)y) = f(\theta Ax + \theta b + (1-\theta)Ay + (1-\theta)b)$$

$$\leq \theta f(Ax + b) + (1-\theta)f(Ay + b)$$

$$= \theta g(x) + (1-\theta)g(y) \quad \therefore \text{得证}$$

20

$$\# g(x) = Af(x) + b,$$

~~g(x) = f(x)~~

$$\# f_i : \mathbb{R}^n \rightarrow \mathbb{R}, i=1, \dots, m \quad \# A \in \mathbb{R}^{n \times m}, b \in \mathbb{R}^m$$

$$g(x) = A^T [f_1(x) \dots f_m(x)]^T + b$$

这个是凸的 因为实质是加权和。  
如果A都非负则凸，否则不确定

两个函数的极大值函数

$$f_1, f_2 \text{ 凸, } \# \max \{f_1(x), f_2(x)\} \text{ 凸}$$

定义域


$$g(\theta x + (1-\theta)y) = \max \{f_1(\theta x + (1-\theta)y), f_2(\theta x + (1-\theta)y)\}$$

$$\leq \max \{\theta f_1(x) + (1-\theta)f_1(y), \theta f_2(x) + (1-\theta)f_2(y)\}$$

$$\leq \theta \max \{f_1(x), f_2(x)\} + (1-\theta) \max \{f_1(y), f_2(y)\}$$

$$= \theta g(x) + (1-\theta)g(y)$$

$$\# \# f(x) = \max \{x_1^2, x_2^2\}$$



n个函数的极大值函数

例2 向量中r个最大元素的和

$x_{i,j}$  为第i行第j大的元素

$$x_{[i,j]} \geq \dots \geq x_{[i,n]}$$

$$f(x) = \sum_{j=1}^r x_{[i,j]} \quad \text{值选取 r 项}$$

$$f(x) = \max \{x_{i,1} + \dots + x_{i,r} \mid 1 \leq i_1, \dots \leq i_r \leq n\}$$

从n个数中，其中最大的组合就是

仿照是凸  
下

$x_{i1} + \dots + x_ir$  和一个组合可以表示为  $(1, \dots, 0, 1, \dots) \cdot \delta$

$$\therefore = \max \{ x^T \delta, \dots, v_{cr} \delta \} \Rightarrow \therefore \text{凸集}$$

无限个函数的极大值

$g(x) = \sup (f_1, \dots, f_n)$  也凸

例：实对称阵的最大特征值

$$f_x = f_2 \lambda_{\max}(x), \quad \text{dom } f = S^m$$

$$8y = xy \Rightarrow y^T 8y = y^T \lambda y \Rightarrow y^T 8y = \lambda \cdot \|y\|_2^2$$

$$\therefore \exists \lambda = \frac{y^T 8y}{\|y\|_2^2} \quad (\text{一个指向 } y \text{ 的一个特征值})$$

使得  $y$  垂直于  $\|y\|_2^2 = 1$

$$\lambda = \max_{\|y\|_2=1} \sup \{ y^T 8y \}$$

$\because y^T 8y$  对应到  $y$  凸（扬言，成立）

$\therefore f_2 \lambda_{\max}(x)$  凸

15/55

函数组合

(某些特殊) 组合也保凸

$$h: R^k \rightarrow R^n, \quad g: R^n \rightarrow R^k$$

$$f: h \circ g: R^n \rightarrow R \quad (\text{先做 } g \text{ 再做 } h)$$

$$f(x) = h(g(x)) \quad \begin{cases} \text{定义域: } & \{x \in \text{dom } g(x)\} \\ & g(x) \in \text{dom } h(x) \end{cases}$$

先看特例，所有都一样，但  $\text{dom } f = R$

判断  $f''(x) \geq 0$

$$\begin{aligned} f' &= h'(g(x)) \cdot g'(x) & f'' &= h''(g(x)) \cdot g(x) \cdot g'(x) + g''(x) \cdot h'(g(x)) \\ & & &= h''(g(x)) \cdot g^2(x) + g''(x) \cdot h'(g(x)) \end{aligned}$$

22

凸函数

① 假设  $g$  凸, 则  $g''(x) \geq 0$ , 则  $f$  也 $h'' \geq 0$  (凸),  $(h'')$   $\geq 0$  非减子阵∴  $g$  凸,  $h$  凸且  $h$  非降②  $g$  凹,  $h$  凸且  $h$  非增, 则  $f$  也

同样可得凹的条件

(一个放大的条件)

高维  $n, k \geq 1$ { $\text{dom } g, \text{dom } h, \text{dom } f \neq \mathbb{R}^n, \mathbb{R}^k, \mathbb{R}^r$ }  $\leftarrow$  缩小  $\text{dom}$  问题 $h, g$  在  $\text{dom}$  可微

与 1 维类似 的中值定理

$$\text{e.g. } h(x) = -\log x \rightarrow h(x) = \begin{cases} -\log x & x > 0 \\ \infty & x \leq 0 \end{cases}$$

①  $h$  为凸  $h$  非降,  $g$  凸, 则  $f$  凸 $h$  凸 非增,  $g$  凹, 则  $f$  凹

凹 非降

凹 非增

证明第一条

(1-空二阶可导)

 $x, y \in \text{dom } h$ ,  $g(x), g(y) \in \text{dom } h$  $\Rightarrow \theta x + (1-\theta)y \in \text{dom } g$ 

$$g(\theta x + (1-\theta)y) \leq \theta g(x) + (1-\theta)g(y)$$

 $h$  为凸,  $h$  在  $\text{dom } h$  为凸 $\therefore \theta g(x) + (1-\theta)g(y) \in \text{dom } h$ 

$$h(\theta g(x) + (1-\theta)g(y)) \leq \underbrace{\theta h(g(x)) + (1-\theta)h(g(y))}_{= \theta f(x) + (1-\theta)f(y)}$$

希望  $f(\theta x + (1-\theta)y) \leq h(\theta g(x) + (1-\theta)g(y))$ 

$$f(\theta x + (1-\theta)y)$$

$$= h(g(\theta x + (1-\theta)y))$$

固有  $\bar{h}$  (下界)

$$g(\theta x + (1-\theta)y) \leq \theta g(x) + (1-\theta)y$$

$$\therefore h(g(\theta x + (1-\theta)y)) \leq h(g(x)) + (1-\theta)y \leq \theta f(x) + (1-\theta)f(y)$$

$$\theta f(x) + (1-\theta)f(y)$$

不能用单调性，因为没有说  $g(\theta x + (1-\theta)y) \in \text{dom } h$

① ②

证  $g(\theta x + (1-\theta)y) \in \text{dom } h$

反证：若  $\notin \text{dom } h$ , 则  $g(\theta x + (1-\theta)y) \in \text{dom } h$

$\because \bar{h}$  不降

用 3 下加性质

(扩展)

$$\bar{h}(g(\theta x + (1-\theta)y)) \leq \bar{h}(g(x) + (1-\theta)g(y))$$

$\therefore$  左边 =  $\infty$ , 右边  $\in \text{dom } h$

$$\therefore h(\infty) \geq \infty \quad (\text{因为 } h \text{ 是凸})$$

即对  $x, y$ , 若有  $h(\infty) = \infty$ , 则解得  $h(x) = \infty$ , 不是我们的定理。

在其它情况下, 充分  $\therefore g(\theta x + (1-\theta)y) \in \text{dom } h$

↓

单调性

$$f(x) + (1-\theta)y = h(g(\theta x + (1-\theta)y)) \leq \theta f(x) + (1-\theta)f(y)$$

例 2 若  $g$  为凸,  $\exp\{g(x)\}$  为凸

$\therefore g$  凸,  $h = \exp(g)$  凸且不降 (即  $f = \exp(g(x))$  凸)

(这些条件适用于两个条件同时满足, e.g. 可微)

例 2  $g$  凸且  $g \geq 0$ ,  $\log(g)$  为凹

$\therefore g$  凸  $\log$  凸, 且为不降

$\therefore \log g$  凹

|b/55| 若  $g$  为凸,  $g > 0$ ,  $\frac{1}{g}$  为凸则  $\frac{1}{g}$  为凹

$\therefore g$  凸  $h = \frac{1}{2} \log g$  对凸, 拓展后不增

$\therefore f$  凸

24

$g$  凸,  $P$  增广  $\geq 0$ ,  $g^P(x)$  弧形  
~~且  $g$  严格凸~~  
~~斜  $h(z) = z^P$~~   
~~把  $z$  看作凹~~  
~~方便扩展保持单调性)~~

他乱了，下节课再讲吧

## 函数的透视

(当透视函数不同时:  $P: R^n \rightarrow R^n$  dom  $P \in R^n \times R^+$   
 $P(\vec{z}, t) = \frac{\vec{z}}{t}$ )

函数  $f: R^n \rightarrow R$   $P_{\text{dom } f} \times R^+$

其透视  $g: R^{n+1} \rightarrow R$

$$g(x, t) = \underline{\underline{t}} f(\frac{x}{t}) \quad (\frac{x}{t} \in \text{dom } f)$$

若  $f$  是凸, 则  $g$  也凸; 若  $f$  凹, 则  $g$  凹

可表达为  $(x, t)$  joint convex

例 1 L2 范数乘以平方

$$f(x) = x^T x \quad x \in R^n$$

$$g(x, t) = t \cdot (\frac{x}{t})^T \cdot (\frac{x}{t}) = \frac{1}{t} x^T x = \frac{1}{t} f(x)$$

例 2 负对数

$$f(x) = -\lg x$$

$$g(x, t) = \frac{1}{t} \cdot (-\lg \frac{x}{t})$$

$$= \frac{1}{t} \cdot \lg(\frac{1}{t}) \quad (x, t) \in R_+^2$$

(用  $f''$  条件判断  $g$ )

将  $x, t$  扩展成  $u, v \in R_+^n$

$$g(u, v) = \sum u_i \cdot \log \frac{u_i}{v_i}$$

$$(\text{因为 } + = \sum g_i(u_i, v_i))$$

这里子是负加权和, 因此希望  $(u, v)$  是同一个

25

又 P 为凸


$$D_{KL}(u, v) = \sum_{i=1}^n u_i \log \frac{u_i}{v_i} (-u_i + v_i) \rightarrow \text{凸}$$

[KL-Divergence 的逻辑， $D_{KL}$  是 Bregman Divergence 的一个特例， $D_{Breg}$ ：  
 定义  $f: R - R$  为凸： $D_B(u, v) = f(u) - f(v) - \nabla f(v)(u-v)$   
 若  $f(u) = \sum_{i=1}^n u_i \log u_i - \sum u_i$ ,  $D_B$  变成  $D_{KL}$   
 但一般  $f$  不一定凸 (即使  $f$  二级可微)]

函数的共轭 (Conjugate)

$$f: R^n \rightarrow R, f^*: R^n \rightarrow R$$

$$f^*(y) = \sup_{x \in \text{dom}} (y^T x - f(x))$$




(之后所有点在左边找, 因为 f(x) &gt; y^T x, y^T x - f(x) \rightarrow -\infty)

①  $f(x)$  若可微, 则  $f^*(x) = f^*(y)$  对应  $f'(x) = y$ ②  $f(x)$  无论  $f(x)$  是不是凸,  $f^*(x)$  一定凸[why  $f^*$  凸, 给定  $x$ ,  $f^*$  是关于  $y$  的 linear function,  
 是 sup, 即对一切  $y$  非 LF 或极小值,  $\therefore f^*$  凸]


17/55

例, 若  $g$  为凸,  $P \geq 1$ , 则  $g(p(x))$  为凸

$$\text{let } h(z) = z^P \quad \text{dom } h \in R_+$$

由  $h(z)$  构造的子梯, 重卦 梯

$$h(z) = \begin{cases} z^P & z \geq 0 \\ 0 & z < 0 \end{cases}$$



6.26

### ③ 極大值/極小值(例)

$$\textcircled{1} f(x) = ax + b$$

$$f'(x) = y = a$$

$$\therefore f^*(y) = \sup_{x \in \mathbb{R}} (-bx - b) = -b(y-a) \quad (y=a) \\ +\infty \quad (y \neq a)$$

$$\textcircled{2} f(x) = -\log x \quad x \in \mathbb{R}_+$$

$$f^*(y) = \sup_{x \in \mathbb{R}_+} (yx + \log x)$$

$$f'(x) = -\frac{1}{x} = y$$

$$\text{当 } y < 0 \text{ 时 } x = \frac{1}{y} > 0 \quad f^*(y) = -\log(\frac{1}{y})$$

$$\text{当 } y \geq 0 \text{ 时, } x = \frac{1}{y} \notin \mathbb{R}_+ \rightarrow +\infty \quad (\text{yx 会变成 } \infty)$$

$$\therefore f^*(y) = \begin{cases} -\log(-y) & y < 0 \\ +\infty & y \geq 0 \end{cases}$$

$$\textcircled{3} f(x) = \frac{1}{2} x^T Q x \quad Q \in S^n_+$$

$$f^*(y) = \sup_{x \in \mathbb{R}^n} (yx - \frac{1}{2} x^T Q x)$$

$$f'(x) = Qx = y \Rightarrow x = Q^{-1}y$$

$$\therefore f^*(y) = y^T Q^{-1}y - \frac{1}{2} y^T Q(Q^{-1})^T Q^{-1}y \\ = y^T Q^{-1}y - \frac{1}{2} y^T Q^{-1}y$$

复数  $(a+bi) \rightarrow (a-bi) \rightarrow (a+bi)$

共轭/共轭是它自身

对  $f$  而言

$$\because f^* \text{ 定义 } \therefore f^{**} = (f^*)^* = f$$

$$\therefore f^* \text{ 定义 } \therefore f \neq f^{**}$$

对于  $f$ , 只有当  $f$  为闭函数,  $f^{**} = f$

## 凸集与凸函数的关系

$\alpha$ -sublevel set

$$C_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\}$$

① 若  $f$  的  $\alpha$ -set 都是凸集

i.e.  $x, y \in C_\alpha$

$$f(\theta x + (1-\theta)y)$$


若  $f(\theta x + (1-\theta)y)$  也  $\leq \alpha$ , 则  $\theta x + (1-\theta)y \in C_\alpha$  例证

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y) \Leftrightarrow \theta \leq \theta \cdot \alpha + (1-\theta)\alpha = \alpha$$

∴ 得证


18/55

② 反过来, 若  $f$  的  $\alpha$ -set 都是凸集, 则  $f$  不一定凸



高维:  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $x \in \mathbb{R}^n$ ,  $(\begin{matrix} x_1 \\ x_2 \end{matrix})$

$$f(x) = x^T x$$



Quasi-Convex function 手写凸函数

① 子-凸是凸函数

② 相对比较优化的一类

$$\text{Quasi Convex } S_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\}$$

即  $f$  的  $\alpha$ -set 是凸的

$\Rightarrow x$  凸圆  
 $\Rightarrow \alpha$  圆

"拟凸"  
拟凸性


28

$e^x$  同时是凹的/凸的/既非


(因为  $e^x$  很像线)

$\text{凸} \Rightarrow \text{拟凸}$ , 拟凸  $\nRightarrow$  凸

拟凸也称‘单模态’。单一峰，但简单，因为很多凸优化算法可直接用在拟凸中。但理论分析比较难




拟凸, 仍能下降到最低点



可是拟凸: 会落停到 local-optima

(这种叫“多模态”)




$f: \mathbb{R}^n \rightarrow \mathbb{R}$  凸的, 则  $\text{dom } f \subseteq \mathbb{R}^n$ ,  $\forall x, y \in \text{dom } f$

$0 \leq \theta \leq 1$ ,  $\theta f(x) + (1-\theta)f(y) \geq f(\theta x + (1-\theta)y)$

对于  $f$  是拟凸时 (仍要求  $\text{dom } f \subseteq \mathbb{R}^n$ )

$\max\{f(x), f(y)\} \geq f(\theta x + (1-\theta)y)$



向量的长度  $x \in \mathbb{R}^n$

$x$  中最后一个非零 entry 的位置

$$f(x) = \begin{cases} \max\{i; x_i \neq 0\} & x \neq 0 \\ 0 & x = 0 \end{cases}$$

向量整列 = 3

29

定义，若  $\{x \mid f(x) \leq \alpha\}$  对所有  $i=1, \dots, r, x_i > 0$

这个 set 是个子空间（一些维是 0）

∴ 子空间凸 ∴  $f$  凸

故

例 1 线性函数

$f(x) = \frac{ax+b}{cx+d}$   $f$  包含凸集，但  $f$  不一定是凸函数，  
但一定 拟凸

$$S_2 = \left\{ x \mid \frac{ax+b}{cx+d} \leq \alpha \right\}$$

$\{x \mid ax+b \leq \alpha cx + \alpha d, cx+d > 0\}$  凸，因为当  $x \in S_2$   
时  $\exists \lambda \in [0, 1]$

19/55

证几何平均  $f(x) = (x_1 \cdots x_n)^{\frac{1}{n}}$ ,  $\text{s.t. } x \in R^n_+, \prod |x_i| \leq 1$  (当作 Quiz)


例 2 向量的零范数 (或称 0-范数)

$$f(x) = \|x\|_0 \quad (\text{即由定义可得})$$

$f(x) \leq \alpha$  @ 一维时,  $\alpha \geq 1$  时,  $x =$

一维时, 只有  $x > 0$  才  $f(x) = 0$ , 其它都是 1

二维时,



∴ ~~不是拟凸~~ 不是拟凸 (+ 非凸)

例 3  $\min \|x\|_0$ , s.t.  $x \in C$  找一个最稀疏的  $x$

松弛的凸优化问题


① 法一：处理成凸的问题 (凸松弛)

$$\min \|x\|_0 \Rightarrow \min \|x\|_1 \quad (\|x\|_1 \text{ 凸})$$

30

凸函数


另一种证明 (n=1)



$n=2$  时

$$\log(\mathbf{x}^T \mathbf{z} + 1)$$

$$x \in C$$



$x_1$  凸

20/55

凸函数的定义

可微凸函数一阶条件

凸  $f$ :  $\text{dom } f$  为凸,  $f(y) \geq f(x) + \nabla f(x)(y-x)$

若  $f$  为凸,  $\text{dom } f$  为凸,  $f(y) \geq f(x) + \nabla f(x)(y-x) \leq 0$   
(存在一个线性关系)

$\nabla f$ :

$n=1$

$\Rightarrow$

$x, y, \max\{f(x), f(y)\} \geq f(\theta x + (1-\theta)y)$

设  $f(y) \leq f(x)$ , 则  $f(x) \geq f(\theta x + (1-\theta)y)$

做一个一阶偏导

$$f(\theta x + (1-\theta)y) - f(x) \leq 0$$

$$\Rightarrow f(\theta x + (1-\theta)y) - f(\theta x + (1-\theta)x) \leq 0$$

$$\Rightarrow \frac{f(\theta x + (1-\theta)y) - f(\theta x + (1-\theta)x)}{(1-\theta)(y-x)} \leq 0$$

$$\left( \theta \rightarrow 1, \frac{\theta}{\sigma} \rightarrow \nabla f(x) \right) \quad \left( \theta \rightarrow 0, \frac{\theta}{\sigma} \rightarrow 0 \right)$$

$$\Rightarrow \nabla f(x) \cdot (y-x) \leq 0$$

$\Leftarrow \forall x, y \in \text{dom } f, \nexists f(y) < f(x) \Rightarrow \nexists f(x) - (y-x) \leq 0$

$$\max \{f(y), f(x)\} = f(\theta x + (1-\theta)y) \quad (\theta \geq 0)$$

( $f(x) \geq f(y)$ )

$$\geq f(x) - f(\theta x + (1-\theta)y)$$

$$= f(\theta x + (1-\theta)x) - f(\theta x + (1-\theta)y)$$

$$= (1-\theta)x - f(\theta x + (1-\theta)y)$$

$$= f'(x)(x-y) \geq 0$$

$$\therefore \max \{f(y), f(x)\} \geq f(\theta x + (1-\theta)y)$$


是的，因为当  $\theta = 1$  时应该

且  $\theta \in [0, 1]$ , 严格递增

21/55

所以若  $\nabla f(x) = 0$ , 则当  $f(y) \leq f(x)$  时  $\Rightarrow \theta \leq 0$  没意义

(这就是为什么平行于  $\nabla f(x)$  的线  $y=x$  无意义)



二阶条件:

$\text{dom } f \subset \mathbb{R}$ , 且  $\nabla^2 f(x) \geq 0 \Rightarrow \nabla^2 f(x) y \geq 0$

$$n=1 \text{ 且 } \nabla f'(x) \geq 0 \Rightarrow \nabla^2 f''(x) \geq 0$$

$$y=0 \text{ 且}$$


$$0 \geq 0 \Rightarrow 0 \geq 0$$

$$y \neq 0, f'(x)=0$$

$$\Rightarrow f''(x) \geq 0 \quad f''(y) \geq 0$$


极值

( $\Rightarrow f''(0) \geq 0$ , 且  $f''(0) \geq 0$  需要这些条件)



可用阶条件判断 f 不是极值

32



log Convex / concave 对数凸/凹

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  to log convex iff  $\log f$  凸

log concave.

同理有 log convex

(用来处理变量的乘积)

$f$  凸,  $\log f$  单增:  $f = x^a \log x$  凸

若  $\log f$  单增,  $f$  凸

(用对数组合系数常含  $g_2 \log f$ , 或  $e^g$   $h = e^g$ )

$g$  增,  $h$  增, 单调下降  $\rightarrow f$  凸

$\log f$  凸,  $f$  单增 (因为  $\log$  单增  $\rightarrow$  凸)

$f$  凸, 则  $\log f$  增

(用逆函数,  $f$  凸,  $\log$  凸 单调  $\rightarrow$  凸)

反对称凸  $>$  单增; 凸  $>$  对称凸

21/55

函数  $\rightarrow$  凸的充要条件

$\Leftarrow$

$x, y$  为  $f$ ,  $f(y) \geq f(x), x \neq y$

$$z = \theta x + (1-\theta)y$$

$$f(x) = \max \{ f(x), f(y) \} \geq f(z) \quad (\sum \text{系数} \geq 1 \text{ 且 } x=y, \theta=0,1)$$

(1)  $f(x) \neq f(z)$ , 无离散点

(2)  $f(x) = f(z)$  }  $\Rightarrow f(x) \in f(z)$  单增

(3)  $f(x) < f(z)$

$\exists \theta \in (0, 1)$  s.t.  $f(x) - f(z) = f'(z)(x-z)$

$\therefore f(y) \leq f(x) \Rightarrow f'(z) \geq f'(y) \quad (z > m)$

$$\begin{aligned} &\text{if } z \leq y \quad \cancel{\text{f}'(z) \geq f'(y)} \\ &\text{if } z \geq y \quad \cancel{\text{f}'(z) \leq f'(y)} \quad ? \text{ if } f' \text{ is } \cancel{\text{continuous}} \end{aligned}$$

$$\left\{ \begin{array}{l} f'(z) \geq f'(y) \\ f'(z) \geq f'(x) \end{array} \right. \rightarrow f'(z)(x-z) \leq 0 \quad \cancel{f'(z)(y-z) \leq 0}$$

~~由題意得  $x, y, z$  在  $f'(z)$  的定義域內，當  $z$  從  $y$  向  $x$  移動時， $f'(z)$  由  $f'(y)$  增加到  $f'(x)$~~

$$\therefore f(y) \leq f(x) \leq f(z) \Rightarrow f(y) \leq f(z)$$

$\forall \theta \in (0, 1)$

$$\left\{ \begin{array}{l} f'(z)((1-\theta)x - (1-\theta)y) \leq 0 \\ f'(z)(-\theta x - \theta y) \leq 0 \end{array} \right. \Rightarrow f'(z)(1-\theta)(x-y) \leq 0 \quad f'(z)(-\theta)(x-y) \leq 0$$

$$\therefore \left\{ \begin{array}{l} f'(z)(x-y) \leq 0 \\ f'(z)(x-y) \geq 0 \end{array} \right. \Rightarrow x=y \quad f'(z)(x-y)=0 \Rightarrow f'(z)=0$$

$\exists z_1 \in [x, y]$ , 使得  $f(z_1) \geq f(x)$

$\because$  同理可得  $f'(z_1) = 0$

$\therefore$  在  $[x, y]$  上  $f'(z) = 0$  時， $f'(z) = 0$

$\therefore$  常數

$$\therefore f(z) = f(x)$$

$\therefore$  因為  $f(x) \leq f(z)$  且  $f(z) = f(x)$

$\therefore f(x) \geq f(z)$  (符合 ①②③)

答  $\max(f_x, f_y) \geq f(x + (1-\theta)y)$

34

## Convex Problem

① 闭合函数  $f$   $\Rightarrow$  凸定义  
b 凸集约束

### 一般的优化问题

$$\min f_0$$

$$\text{s.t. } \begin{cases} f_i(x) \leq 0 & \leftarrow \text{等式约束} \\ h_j(x) = 0 & \leftarrow \text{没有等式 '无约束问题'} \end{cases}$$

$x$  优化变量  $f$  目标函数

最优解:

$$\text{若可行解集 } \neq \emptyset \rightarrow p^* = \inf\{f_0(x) | x \in X_f\}$$

若  $X_f$  空集  $\rightarrow$  问题的设置或解法出错了

(因为开区间义了), 则  $p^* = +\infty$

若  $x^*$  可行, 且  $p^* = f_0(x^*)$

称为  $x^*$  为最优解


最优解的集合称为最优解集, 记为  $\Omega$

次优解集

Satisficing solution

对工程问题足够的解

$$X_\varepsilon = \{x \in X_f | f_0(x) \leq p^* + \varepsilon\}$$




### 局部最优解

(有可能局部全局解)


$$f_0(x) = \inf \{ f_i(x) \mid f_i(x) \leq 0, h_i(x) = 0, \|z - x\| \leq R \}$$

$\exists R > 0$  使  $x$  局部最优


22/55



取值



$X_{loc}$  局部最优解集



最优解  $\subset$  局部最优解

但 E-次优和局部最优无包含关系

局部最优  $\subset$  可行集

为什么都是 ' $\leq$ ', 不是 ' $<$ '?

(active)

若  $x \in X_F$  且  $f_i(x) = 0$ , 则  $f_i(x) \leq 0$  表示 活动约束 (基约束起作用且在边  
界上)  $\rightarrow f_i(x) < 0$  非活动约束 (inactive)

$\leq$  可能有解

当我们把 " $\leq$ "  $\rightarrow$  " $<$ ", 则

为 ' $\leq$ ' 的特

征形式

s.t.  $f_i(x) \leq 0 \rightarrow$

$x^*$  时活动 等价  $f_i(x) < 0$

$f_i(x) < 0$  有理, 因为实数上是在界  
上取到的 (可能会数学来源的定理)

e.g. s.t.  $money < 100$  没有意义

$\downarrow$  现实  $\downarrow$  成

$money \leq 100$

问题)

这样限制就是  $money$

$\in (0, 100)$

$money \leq 100$

+ 无限点

$|log(100 - money)| > 0$

36

可行解优化问题 feasible problem

目标是最大，优化是  $x^*$

$$\begin{aligned} \text{find } & x \\ \text{s.t. } & f(x) \leq 0 \\ & g(x) = 0 \end{aligned}$$

$$\text{find } \min O$$

$$\text{s.t. } -$$

等价问题

例2 Box Constraints

$$\min f(x)$$

$$\text{s.t. } l_i \leq x_i \leq u_i$$

$$\textcircled{1}$$

$$l_i - x_i \leq 0$$

$$x_i - u_i \leq 0$$

等效

$$\text{例2 } \min \alpha f(x) \quad (\$ \min f \text{ 等价})$$

$$\text{s.t. } \alpha f(x) \leq 0 \quad (\alpha > 0)$$

$$\beta_i h_i(x) = 0 \quad (\beta_i \neq 0)$$

现实意义：约束量级不一样， $f_1(x) \leq 1000$ ,  $f_2(x) \leq 0.001$ ,

$$f_2(x) \leq 0.001$$

缩放后相当于 normalize

松弛函数

例1.  $y_0 \in R$  单增

$$\psi_1, \dots, \psi_m: R \rightarrow R \quad \psi_i(u) \leq 0 \iff u \leq 0$$

$$Q_1(u) = 0 \iff u = 0$$

↓

$$\min. \quad Y_0(f(x))$$

$$\text{s.t. } \psi_i(f(x)) \leq 0$$

$$Q_i(f(x)) = 0$$

例:  $\min \|Ax - b\|_2 \Leftrightarrow \min \|Ax - b\|_2^2$  (相当于  $y_i = x^2$  (若  $x > 0$  时))

例: 消除等式约束

(约束越多, 求解越复杂)

$$\left\{ h_i(x) = 0 \right\} \text{一组方程} \Leftrightarrow x = Q(z) \text{ 等价}$$

$(Z \in R^K, Q: R^K \rightarrow R^n)$

如果能找到合适  $Q$  和  $Z$ ,

$$\begin{array}{ll} \min f_0(x) & \min f_0(Q(z)) \\ \text{s.t. } f_i(x) \leq 0 & \text{s.t. } f_i(Q(z)) \leq 0 \\ x = Q(z) & \text{变成关于 } z \text{ 的优化} \\ & \downarrow \\ & x^* = Q(z^*) \end{array}$$

但消除不一定保证更简单

例: 消除线性约束  $Ax - b = 0$

$$A \in R^{P \times n} \Rightarrow x = Q(z)$$

①  $Ax - b = 0$  无解, 则  $x_f = \emptyset$

②  $A$  可逆,  $x = A^{-1}b$

③ 充分  $x = \theta z + (x_0)$  ( $\theta$  为接尾阵)  $\geq R^{n-r}$

$Ax_0 = b$

$A \not\approx AF = 0$

23/55

当  $h_i(x) = a_i^T x_i = b_i$ , 称为“狭义”的凸问题

狭义  $\Rightarrow$   $x$  的区域

$$\text{例: } \min f_0(x) = x_1^2 + x_2^2$$

$$\text{s.t. } f_1(x) = \frac{x_1}{1+x_2} \leq 0 \quad \text{狭义矛盾}$$

$$h_1(x) = (x_1 + x_2)^2 = 0$$

$\cup$  变化

$$\text{s.t. } x_1 \leq 0 \rightarrow \underline{\text{f}_1}$$

$$x_1 + x_2 = 0 \rightarrow \text{affine}$$

$$\begin{aligned} \text{优化} & \min f_0(Fz + x_0) \\ \text{s.t. } & f_i(Fz + x_0) \leq 0 \quad (\text{2个 affine 变为 } x = Fz + x_0) \end{aligned}$$

优点：①降低维数  
②减少约束维数

$$\text{问题 } (\text{Simpler}) \Leftrightarrow \text{f_0求解 } x_0 \text{ 且 } x = Fz + x_0$$

SP维数 - 1 (1维)

当  $f_i(x), h_i(x)$  非affine

↓

$$\begin{aligned} \text{引入 } s_i & \text{ s.t. } s_i \leq 0 \quad \text{松弛变量 } s_i \\ f_i(x) - s_i &= 0 \quad (\text{affine}) \\ h_i(x) &\geq 0 \end{aligned}$$

Quasi-convex problem:

$f_i(x)$  凸,  $h_i(x)$  仿射 (约束集为凸集), 目标函数非凸

$f_0$  为非凸凸

$\max$  concave function =  $\min$  convex function

问题的性质：

局部最优 = 全局最优

设  $x$  局部最优： $\exists R > 0 = f_0(x) = \inf \{f_0(z) | \|x-z\| \leq R, z \text{ 可行}\}$

假设  $x$  不是全局最优，即存在  $y$ , 使  $f_0(y) < f_0(x)$

$\exists y \text{ 可行 } f_0(y) < f_0(x)$ , 则  $x$  局部最优

$$\therefore \|y-x\|_2 > R$$

$$\text{构造 } z = \theta y + (1-\theta)x$$

$$\theta = \frac{R}{2\|y-x\|_2} \in (0, \frac{1}{2})$$

$\therefore f_0(z) \text{ 且 } z \text{ 可行}$

$$f_0(z) \leq \theta f_0(y) + (1-\theta)f_0(x)$$

$\therefore z \text{ 在 } \|x-z\|_2 \leq R \text{ 中}$

$$\|z-x\|_2 = \theta \|y-x\|_2 > \frac{R}{2}$$

$$\therefore z \in \{x | \|x-z\|_2 \leq R\}$$

$\therefore f_0(x) \leq f_0(z)$  ( $\because x$  局部最优)


$$\begin{cases} f_0(x) \leq f_0(z) \\ f_0(z) \leq \theta f_0(y) + (1-\theta) f_0(x) \end{cases}$$

$f_0(y) \leq f_0(x)$

$$\therefore f_0(y) < f_0(x) \leq f_0(z)$$

$$\therefore \theta f_0(y) + (1-\theta) f_0(x) < f_0(z)$$

矛盾  $\therefore x$  全局最优



## ② 用梯子 $f_0$ 可微时


(假设  $f_0$  可微:  $f_0(x) \Leftrightarrow f_0(y) \geq f_0(x) + \nabla f_0(x)(y-x)$ )

设可行域  $X_f = \{x \mid f_i(x) \leq 0, i \in \mathcal{N}\} \cap \text{dom } f_0$

$x^*$  最优  $\Leftrightarrow \nabla f_0^T(x^*)(y-x^*) \geq 0$

(?) 梯子  
有理数  
中等


证明: 设  $\text{dom } f_0 = X_f$ , 若对任意  $y$  使  $\nabla f_0^T(x^*)(y-x^*) \geq 0$  对  $\forall y \in X_f$ ,  
则由  $f_0$  性质  $f_0(y) \geq f_0(x^*) + \nabla f_0(x^*)(y-x^*)$



24/55

补充说明: 加上这个点, 仍然 f\_0 > 0, 因为在 X\_f

40



$$\nabla f(x^*)(y-x) \geq 0$$

梯度下降

例 12 约束极值问题的强解

若  $\exists X, Ax=b, X^* \Leftrightarrow \forall y, Ay=b, \nabla f(X^*)(y-X^*) \geq 0$   
 $\because Ax=b, Ay=b \therefore y = x + v \text{ (VGA), } Av=0$   
 $\nabla f(x^*)(y-x) = \underline{\nabla f(x^*)} \cdot V \geq 0 \text{ 对 } \forall V \text{ (VGA)}$


由此可见  $\nabla f$  的要求很强。

$A=I^2$   $f$  只有①零空间变没零

或②梯度沿零空间方向平行于零空间

Case 1:  $V=0 \Rightarrow y=x \Rightarrow Ax=b$  有唯一解,  $A$  可逆  $X=A^{-1}B \quad X_f=\{A^{-1}B\}$

2:  $V \neq 0 \Rightarrow \nabla f \cdot V \geq 0 \therefore \nabla f(X^*) \cdot V \geq 0$



$Ax=b$  ( $A$  可逆),  $A$  的零空间为直角

$$\{x \mid Ax=0\}$$

$\nabla f \in Ax=0$  为零空间垂直

例：约束仅为非负约束

$$\min f(x)$$

$$\text{s.t. } x \geq 0$$

若  $\exists x, x^* \Leftrightarrow y \geq 0 \quad \nabla f(x) \cdot (y-x) \geq 0$

$$\nabla f(x) \cdot y - \nabla f(x) \cdot x$$

① 若  $\nabla f(x) \leq 0$ , 则  $\nabla f(x) \cdot y - \nabla f(x) \cdot x \geq 0$  取充分小，(因为  $y \geq 0$ ) 则  $\nabla f(x) \cdot y - \nabla f(x) \cdot x \geq 0$

② 取充分大  $\nabla f(x) \cdot x \leq 0$


③ 结合 ①②, 有  $\nabla f(x) = 0 \Leftrightarrow \nabla f(x) \geq 0, x \geq 0 \quad \therefore \nabla f(x) \cdot x \geq 0$

$\therefore \nabla f(x) \cdot x \leq 0 \quad \therefore \nabla f(x) = 0 \quad \nabla f(x) \cdot x \geq 0$

$$\therefore \begin{cases} x \geq 0 \\ \nabla f(x) \geq 0 \\ \nabla f_i(x) \cdot x_i = 0 \end{cases}$$

最优解的条件，称为互补条件 (由一阶条件衍生出)

即  $\nabla f_i(x) = 0 \text{ 或 } x_i = 0$



### 典型的凸问题

线性规划 (目标和约束均为线性)

$$\min c^T x + d \quad c \in \mathbb{R}^n \quad d \in \mathbb{R}$$

$$\text{s.t. } Ax \leq b \quad A \in \mathbb{R}^{m \times n} \quad b \in \mathbb{R}^m$$

$$Ax = b \quad A \in \mathbb{R}^{k \times n} \quad b \in \mathbb{R}^k$$




由稠度问题发展来

42

### LP线性规划

25/55

$X^*$  是最优解



易得  $X^* > 0$

$\nabla f(x^*)$

对 LP, 一定有一个  $X^*$  在顶点 (但可能  $X^*$  在整条边)

这个是 LP 的优势, 即 P 顶点,

等价形式

$$\min c^T x + d \quad \xrightarrow{\text{将 x 分成正负}} \min c^T x^+ - c^T x^- + d$$

$$\text{s.t. } Ax + \begin{bmatrix} 0 \\ s \end{bmatrix} \geq \begin{bmatrix} b \\ 0 \end{bmatrix} \text{ 和 } \left\{ \begin{array}{l} x^+ = \begin{bmatrix} x_1^+ \\ \vdots \\ x_n^+ \end{bmatrix} \\ x^- = \begin{bmatrix} x_1^- \\ \vdots \\ x_n^- \end{bmatrix} \\ x = x^+ - x^- \\ x^+, x^- \geq 0 \end{array} \right. \quad \xrightarrow{\text{将 x 分成正负}} \quad \text{s.t. } Ax^+ - Ax^- = b \\ s \geq 0$$

$$Ax = b \quad \left( \begin{array}{l} x_1^+ \\ \vdots \\ x_n^+ \end{array} \right), \quad Ax^- = 0 \quad Ax^+ - Ax^- = b$$

$$x^+ = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}, \quad x^- = \begin{bmatrix} x_1^- \\ \vdots \\ x_n^- \end{bmatrix}$$

$$x = x^+ - x^-$$

$$x^+, x^- \geq 0$$

优先: 等式约束是  $\geq 0$

1) 规范写成

$\min c^T x \rightarrow$  由  $x$  包含  $x^+, x^-$  和  $s$

$$\left\{ \begin{array}{l} \text{s.t. } Ax = b \\ x \geq 0 \end{array} \right.$$

例 2 食谱问题

$m$  种营养元素  $a_{ij}, \dots, b_m$

$n$  种食谱, 单位营养为  $a_{ij}, \dots, a_{nj} \quad j=1, \dots, n$

目标: 单位食物价格  $c_j$ , 成本价最小

设食物量  $x_1, \dots, x_n \quad \min \sum c_j x_j$

$$\text{s.t. } \sum_{j=1}^n a_{ij} \cdot x_j \leq b_i \quad (i=1, \dots, m)$$

$$x_i \geq 0$$

43

$$\Rightarrow \min_{\mathbf{x}} \quad [c_1 \dots c_n] \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

s.t.  $\begin{bmatrix} a_{11} \dots a_{1n} \\ \vdots \\ a_{m1} \dots a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \geq \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}$

$$\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \geq 0$$

(在现实中有时要求  $x_i = \text{int}$ , 则非凸)

是

例: 线性分式规划 Linear fractional programming

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad (\text{一个线性函数 } \frac{c^T \mathbf{x} + d}{e^T \mathbf{x} + f} < * \text{ 非凸, 因为 } \frac{1}{x} \text{ 不凸})$$

$$P_0 \quad \begin{array}{l} \text{s.t. } G\mathbf{x} \leq \mathbf{h} \\ A\mathbf{x} = \mathbf{b} \end{array}$$

(前提条件  $Af \neq \emptyset$ , 否则无法转换)

$$P_1 \quad \begin{array}{l} \min_{\mathbf{y}} c^T \mathbf{y} + d \\ \text{s.t. } G\mathbf{y} - h \leq 0 \\ A\mathbf{y} - b = 0 \\ e^T \mathbf{y} + f = 1 \\ z \geq 0 \end{array}$$

即:

$$(1). \text{若 } \mathbf{x} \in P_0 \text{ 可行} \quad y = \frac{x}{e^T x + f}, \quad z = \frac{1}{e^T x + f} \quad \text{构造的方法}$$

$$G\mathbf{x} \leq \mathbf{h} \quad \frac{G\mathbf{x} - \mathbf{h}}{e^T \mathbf{x} + f} \leq 0 \quad z \geq 0$$

$$A\mathbf{x} = \mathbf{b} \quad \frac{A\mathbf{x} - \mathbf{b}}{e^T \mathbf{x} + f} = 0$$

$$e^T \mathbf{x} + f \geq 0 \quad (\text{by def}) \quad \frac{e^T \mathbf{x} + f}{e^T \mathbf{x} + f} = 1$$

$$f_0(\mathbf{x}) = c^T \mathbf{y} - hz$$

$$(2). \text{若 } y, z \in P_1 \text{ 可行, 则 } \mathbf{x} = \frac{\mathbf{y}}{z} \quad (\text{由 } z \geq 0 \Rightarrow z > 0)$$

若  $z = 0$  时, 则  $y, z$  不可行(矛盾)无法构造  $\mathbf{x}$ , 设  $\mathbf{x}_0, \mathbf{y}_0 \in P_1$  可行解一个, 且

$$\mathbf{x} = \mathbf{x}_0 + t\mathbf{y}_0 \quad P_1 \text{ 可行} \quad (t \geq 0)$$

$$\because z = 0 \quad \therefore G\mathbf{y} \leq 0 \quad A\mathbf{y} = 0 \quad e^T \mathbf{y} = 1 \quad (P_1 \text{ s.t.})$$

$$\therefore \exists t \in \mathbb{R} \quad \mathbf{x} = \mathbf{x}_0 + t\mathbf{y}_0 \in P_1 \quad z = t > 0$$

$$G\mathbf{x} = G\mathbf{x}_0 + G\mathbf{y}_0 \leq h + (G\mathbf{y}_0)t \leq h$$

$$A\mathbf{x} = A\mathbf{x}_0 + tA\mathbf{y}_0 = A\mathbf{x}_0 + tb = b$$

26/55

44.

$$e^T x + f = e^T x_0 + f + t \quad \text{for } t > 0$$

$\therefore x = x_0 + t y$  也可行

$$\text{但 } f_0(x) = f_0(y, z)$$

$$P_1 \quad P_1$$

$$f_0(x) = \frac{c^T x_0 + c^T t y + d}{e^T x_0 + e^T t y + f} \text{ 我令 } t \text{ 使 } z = c^T y$$

取  $t \rightarrow +\infty$


$$f_0(x) \rightarrow \frac{c^T t y}{e^T t y} \because e^T t y \rightarrow +\infty = c^T y$$

二次规划 Quadratic P

$$\min: f(x) = \frac{1}{2} x^T P x + q^T x + r, \quad P \in S^n \quad \text{= 次数}$$

$$\text{s.t. } Qx \leq b \quad \text{且 affine}$$

$$Ax = b$$



$$\nabla f(x^*)^T(y-x)$$

二次约束二次规划 QCP

$$\text{s.t. } y_i = \theta_j + x, \quad Ax = b$$

$$\sum p_i^T x_i + q_i x_i + r_i \leq 0$$

B1. 带噪声的图像去噪

$$b = Ax + e \quad \text{信号恢复}$$

$$\hat{x} = \underset{x}{\operatorname{argmin}} \|b - Ax\|_2^2$$

$$= \underset{x}{\operatorname{argmin}} \|b - Ax\|_2^2$$

$$= \underset{x}{\operatorname{argmin}} \|x^T(A^TA)x - 2b^TAx + b^Tb\|$$

$A^TA \in S^n_+$

若  $A$  可逆  $(A^{-1}A)^{-1}\hat{x} = (A^TA)^{-1}A^Tb$  ( $\Rightarrow f=0$ )

增加先验知识:

① L1 软限制  $\Rightarrow \hat{x} = \operatorname{argmin} \|Ax-b\|^2 + \lambda_0 \|x\|_0 \rightarrow$  可能解疏

$\because \|x\|_0 \geq \|\bar{x}\|_1 \therefore$  近似  $\bar{x}$  的  $\|x\|_1$

$$\hat{x} = \operatorname{argmin} \|Ax-b\|^2 + \lambda_1 \|x\|_1 \leftarrow L_1\text{-regularized least square}$$

$(\text{Lasso})$

例  $x = x^+ - x^-$  (适用于 LPA & QP)

$$\hat{x} = \operatorname{argmin} \|b - Ax^+ + Ax^- - \|_2^2 + \lambda_1 \|x^+ - x^-\|_1$$

$$= (\lambda_1 J^T x^+ + \lambda_1 J^T x^-) \quad \text{for } J$$

$$+ \text{s.t. } x^+, x^- \geq 0$$

例: L2-regularized least square (岭回归)

先验:  $x_i$  差别不大

$$\hat{x} = \operatorname{argmin} \|Ax-b\|^2 + \lambda_2 \|x\|_2^2 \quad \text{QP}$$

如果  $L_2$ -时  $\sum_i x_i$   $\xrightarrow{\text{from}}$   $\xrightarrow{\text{to } bl_2}$   $\xrightarrow{\text{to } \lambda_2}$   $\xrightarrow{\text{正则化项}}$

↓ 存在且仅两个等价对子个数是  $\lambda_2$

例:

$$\operatorname{argmin} \|b - Ax\|_2^2$$

$$\text{s.t. } \|x\|_2^2 \leq 0$$

27/55 例: 投资组合问题 portfolio

n 种投资, 各投资  $x_1, \dots, x_n$  元, 最终收入  $p_1 x_1, \dots, p_n x_n$

$$\max p_1 x_1 + \dots + p_n x_n$$

$$\text{s.t. } \sum x_i \leq B \quad \text{(本金 budget)} \rightarrow \sum x_i = B \quad \text{(现实意义)}$$

$x_i \geq 0$  股 银行

假设三种投资  $\bar{p} = [1.05, 1.05, 1]$  (考虑随机性, 看  $E$ )

$$\Sigma = \begin{bmatrix} 1.2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix} \quad (V_r)$$

4.6

半正定矩阵

$$\min \mathbf{x}^T \Sigma \mathbf{x}$$

一个凸模型很重要

$$\text{s.t. } \bar{P}^T \mathbf{x} \geq r_{\min}$$

$$\mathbf{I}^T \mathbf{x} = B$$

$$\mathbf{x} \geq 0$$

半定规划

$$\min \text{tr}(C\mathbf{x})$$

$$\text{s.t. } \text{tr}(A_i \mathbf{x}) = b_i$$

$$\mathbf{x} \geq 0$$

$$\mathbf{x} \in S_+^n, C \in R^{n \times n}, A \in R^{m \times n} \text{ b} \in R^m$$

是矩阵空间内的线性规划问题

(因为取 trace 之后是线性的)

例2 对角矩阵  $C, A, \mathbf{x}$

$$\vec{\mathbf{x}} = \text{diag}(\mathbf{x})$$

$$\min \text{tr}(C\mathbf{x}) = (\vec{C})^T \cdot (\vec{\mathbf{x}})$$

$$\text{s.t. } -(\vec{A}_i)^T \cdot (\vec{\mathbf{x}}) = b_i$$

$$\text{diag}(\mathbf{x}) \geq 0$$

是关于  $\vec{\mathbf{x}} = \text{diag}(\mathbf{x})$  的线性 LP

例3  $\min \mathbf{c}^T \mathbf{x}$

$$\text{s.t. } (X, A_1 + \dots + A_n, B) \rightarrow \text{半定集}$$

$$\mathbf{x} \in R^n / B, A_1, \dots, A_n \in S^k, C \in R^{n \times k}$$

是线性矩阵等式， $S^k$  集

例4  $A(\mathbf{x}) = A_0 + A_1 x_1 + \dots + A_n x_n$

$$A_i \in R^{p \times q}, i=0 \dots n, \mathbf{x} \in R^n$$

谱范数  $\|A(x)\|_2 = A(x)$  最大奇异值

找到一个  $x$ , 最小化谱范数

$$\min \|A(x)\|_2$$

$$\text{等价} \quad \|A(x)\|_2 \leq \sqrt{s}, s > 0 \Leftrightarrow A^T(x) \cdot A(x) - s \cdot I \leq 0$$

$$\min \sqrt{s}$$

$$\text{等价} \quad \frac{\|A(x)\|_2}{\sqrt{s}} \leq 1 \quad \Leftrightarrow A^T(x) \cdot A(x) \leq I \quad \text{对 } x, s \text{ 有 } s.t. \quad \frac{\sqrt{s}}{x} = 0$$

28/55

$$\min_t$$

$$\text{s.t. } \begin{bmatrix} tI & A(x) \\ A^T(x) & tI \end{bmatrix} \geq 0$$

$$t \geq 0$$

$$\min_t$$

$$\text{s.t. } Y = \begin{bmatrix} tI & A(x) \\ A^T(x) & tI \end{bmatrix}$$

$$Y \geq 0$$

$$t \geq 0$$

多目标优化

$$\min f_0(x) \quad (R^n \rightarrow R^q, q \text{ 个输出})$$

$$\text{s.t. } f_i(x) \leq 0$$

$$h_i(x) = 0$$

帕累托最优面

例 2 portfolio

$\min$  risk, - income

s.t. Resource


发展

$\min$  - speed, - quality

s.t. Resource

最

优



帕累托最优面

Oracle solution: 该方向都最小的点 (帕累托点)

quality ↑

value  
frontier

speed

pareto optimal

value  
frontier

48

一个特殊的多目标问题是

若  $\{f_i(x)\}$  在  $\mathbb{R}^k \rightarrow \mathbb{R}^m$ ,  $f_i(x)$  分别, 则可以由下述方法求 Pareto 点:

$$\min \sum_{i=1}^m \lambda_i f_i(x) \quad (\lambda_i > 0)$$

$$\text{s.t. } f_i(x) \leq 0 \quad \text{非负制加权}$$

通过 iterate  $\lambda_i$  可找到所有 Pareto 点

最优化成单目标:

$$\text{e.g. } \max \text{ quality}$$


$$\text{s.t. } \text{speed} > 5$$

例: 山羊问题

$$b = Ax + e \quad \min \|Ax - b\|^2 + \lambda_2 \|x\|^2$$

山羊目标

$$\min \|Ax - b\|^2, \quad \min \|x\|^2$$



最小化

乘积

$$\text{或 } \min \|Ax - b\|^2$$

$$\text{s.t. } \|x\|^2 \leq \varepsilon$$

29/55 对偶性 Duality

凸分析的核心

$$\min f(x)$$

$$\text{s.t. } f_i(x) \leq 0$$

$$h_i(x) = 0$$

$$x \in R^m \quad D = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=p}^l \text{dom } h_i$$

$p^*$  optimal value

Lagrangian function.

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

$$\begin{matrix} \text{向量 } \lambda = \\ \lambda \in R^m \\ \text{VERP} \end{matrix}$$

入：拉格朗日乘子  
✓

关于  $\lambda, v$  都是线性的

↓ 构造

Lagrangian dual function

$$g(\lambda, v) = \inf_{x \in D} L(x, \lambda, v)$$

(1)  $\boxed{g \text{ 一定 是 凸 函 数}}$

$$\left( \sup_{x \in D} L(x, \lambda, v) \text{ 是凸的, 因为关于 } \lambda \text{ 和 } v \text{ 是线性的} \right)$$

$$\left( \inf_{x \in D} L(x, \lambda, v) \rightarrow \text{关于 } \lambda, v \text{ 是线性的, 为凸函数} \right)$$

最优值

(2)  $\forall \lambda \geq 0, \forall v, g(\lambda, v) \leq p^*$

证：设  $x^*$ , 由  $x^* \in X_f$ , 有  $f_i(x^*) \leq 0, h_i(x^*) = 0$

当  $\lambda \geq 0, v \geq 0$ , 有  $\sum \lambda_i f_i(x^*) + \sum v_i h_i(x^*) \leq 0$

$$\begin{aligned} g(\lambda, v) &\leq L(x^*, \lambda, v) = f(x^*) + (\sum \lambda_i f_i(x^*) + \sum v_i h_i(x^*)) \\ &\leq f(x^*) \end{aligned}$$

得证

极大化  $g(\cdot)$ , 得最逼近  $p^*$

50

“ $g$  凸,  $\max \psi = \min \varphi$

又:  $\lambda \geq 0$  成立  $\therefore \max g$  为凸问题

目标为得到  $\lambda$  可能接近的子界

$$\text{例: } \min x^T x \quad \text{s.t. } Ax = b$$

$$L(x, \lambda, v) = x^T x + v^T (Ax - b)$$

$$g(v) = \inf_{x \in D} (x^T x + v^T (Ax - b))$$

$$= \inf_{x \in D} x^T x + v^T x$$

$$\text{① 一阶导数 } \nabla_x x^T x + A^T v = 0 \quad x = -\frac{1}{2} A^T v \quad \text{代入得}$$

$$g(v) = \inf_{x \in D} \left( \frac{v^T A A^T v}{4} - \frac{v^T b}{2} \right)$$

$$= -\frac{v^T A A^T v}{4} - b^T v$$

$$(3) \min c^T x$$

$$\text{s.t. } Ax = b$$

$x \geq 0$  (注意这里是  $-x \leq 0$ )

$$L(x, \lambda, v) = c^T x - \lambda^T x + v^T (Ax - b)$$

$$= (c^T - \lambda^T + v^T A)x - v^T b$$

$$g(\lambda, v) = \inf_x L(x, v, \lambda)$$

(1) 如果  $v$  数值为 0, 则  $g = -v^T b$

(2)  $v \neq 0$ , 则  $g = -\infty$

$$-b^T v - A^T v - \lambda + c = 0 \quad \text{一起解}$$

$$\begin{cases} -b^T v & \text{if } A^T v - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}$$

P.  $b^T v - b^T v$  时即获得  $g$  凸 ( $\rightarrow$  是封闭)

$\therefore -b^T v$  为

凸的 & 凸

51

例:  $\min Z^T W X$  ( $W$  为需飞空)

s.t.  $x_i = \pm 1$  binary 約束

11

$$\overline{x_i^2} - 1 = 0$$

$$L(x, v) = \hat{y}^T W \hat{y} + \sum_i v_i (x_i^2 - 1)$$

$$= \mathbf{g}^\top (\mathbf{W} + \text{diag}(\mathbf{V})) \mathbf{g} - \mathbf{1}^\top \mathbf{V}$$

30/55

$$g(x), g(v) = \inf (\mathbf{x}^\top (w + \text{diag}(v)) \mathbf{x} - \mathbf{1}^\top v)$$

周易之序

day 453

$$S - \mathbf{1}^T V \quad (\text{当 } (V + \text{diag}(Y)) \geq 0)$$

otherwise

### 函数的共轭(与对偶的关系)

找寻  $R \rightarrow R$  的共轭

$$\text{若 } f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x)) \quad (\text{f}^* \text{是凸的})$$

$$13) \frac{1}{2} \min f(x), \text{ s.t. } x=0 \Rightarrow \min = f(0)$$

$$L(x, v) = f(x) + v \cdot x \quad (x \in \{0\}^n, v \in \mathbb{R}^n)$$

$$g(v) = \inf_x (f(x) + vx) = -\sup_x (-f(x) - vx) = -\sup_x (-vx - f(x))$$

$\chi E \zeta \sigma \}$   $\chi E \# \text{danf}$

$$\therefore g(v) = f^*(-v)$$

$$\text{例: } \min f(x). \text{ s.t. } Ax \leq b, cx = d$$

$$L(x, \lambda, v) = f_0(x) + \sum_i \lambda_i^T (Ax - b) + v^T (Cx - d)$$

$$= f_0(x) + (\lambda^T A + v^T c) x - \lambda^T b - v^T d$$

$$g(\lambda, v) = \inf_{x \in \mathbb{R}^n} (f_0(x) + (\lambda^\top A + v^\top C)x) = -\sup_{x \in \mathbb{R}^n} (-(\lambda^\top A + v^\top C)x - f_0(x))$$

$$= f^* \left( -(\lambda^T A + V^T c)^T \right) = \lambda^T b - V^T d$$

要仔细地看  $\text{dom } f^*$  是

52

$$(D) \begin{cases} \max g(\lambda, v) \\ \text{s.t. } \lambda \geq 0 \end{cases}$$

这又是最优值 dual\* (duality problem)

$$(P) \begin{array}{l} \min f(x) \\ \text{s.t. } f_i(x) \leq 0 \\ b_i(x) = 0 \end{array}$$

primary problem

$$\textcircled{1} d^* \leq p^*$$

\textcircled{2} ~~d 是一个约束~~  $\lambda^*, v^*$ : optimal r-lagrange multiplier  
也是对偶问题最优解

例:  $\min C^T x$ , s.t.  $AX=b, x \geq 0$

$$g(\lambda, v) = \begin{cases} -b^T v & A^T v - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}$$



这一块无意义的对偶可丢掉

$$\begin{array}{ll} \max -b^T v \\ \text{s.t. } \begin{array}{l} x \geq 0 \\ A^T v - \lambda + c = 0 \end{array} \end{array}$$


(若  $A^T v - \lambda + c \neq 0$  时, 即无义)



$$\boxed{\min b^T v} \quad \text{s.t. } A^T v + c \geq 0$$

注意  $\min b^T v$  等于  $\max -b^T v$ , 但 最优值并不一样

(是最低的  $v$  是用  $\lambda=0$ )



例:  $\min C^T x$  s.t.  $Ax \leq b$

$$\Rightarrow L(x, \lambda) = C^T x + \lambda(Ax - b)$$

$$= (C^T + \lambda A)x - \lambda b$$

$$g(\lambda) = \inf x (C^T + \lambda A)x - \lambda b$$

$$= -\sup (- (C^T + \lambda A)x + \lambda b)$$

$$= \inf (- \lambda b) +$$



$$\textcircled{1} \quad C^T + \lambda A = 0 \quad g(\lambda) = -b^T \lambda$$

$$\textcircled{2} \quad \text{else} \quad g(\lambda) = -\infty$$

$$\Rightarrow \max_{s.t. \lambda \geq 0} -b^T \lambda \quad \min_{s.t. \lambda \geq 0} b^T \lambda \quad D2$$

$$\left. \begin{array}{l} s.t. \lambda \geq 0 \\ C^T + \lambda A = 0 \end{array} \right\} \Rightarrow \left. \begin{array}{l} s.t. \lambda \geq 0 \\ C^T + \lambda A = 0 \end{array} \right\} \quad \text{很像}$$

$b$ -待定问题，将  $x$  换成  $\lambda \Rightarrow \min_{s.t. A\lambda = b} C^T \lambda$

$$P1 \quad \lambda \geq 0$$

$$\text{本例} \quad \min C^T X$$

$$s.t. \cancel{A \leq b}$$

$$P2 \quad -AX + b \geq 0$$

$$b-331/bx\leq 33 \quad \min b^T X$$

$$s.t. AX + c \geq 0$$

也很像

$\otimes$  说  $P_2$  是  $P_1$  的对偶的对偶是  $P_1$  自身

(对偶的对偶是原问题)

(max 凸函数)

(因  $f^{**}(x) = f(x)$  因此,  $P \Leftrightarrow D(D(P)) = P$  )

$D(D(P)) = P$  的条件 (1)

$$\Rightarrow LP \text{ 例} \quad \min C^T X$$

$$P_1, P_2 \text{ 的对偶} \quad s.t. AX = b \quad (\text{CP 问题}) \quad \text{很像}$$

$D$ ,  $X$  为  $P$  问题,  $X$  为  $P$  问题  $\Leftrightarrow$   $A$  为  $P$  问题

若  $P^* = D^*$  (1)

54


31/55  $d^* = p^*$  的条件  $\begin{cases} d^* \leq p^* \\ d^* = p^* \end{cases}$  弱对偶  
强对偶

对偶问题  $p^* \leq d^*$

定义:  $D$  的 relative interior :=  $\text{Relint } D$

$\text{Relint } D = \{x \in D \mid B(x, r) \cap \text{aff } D \subseteq D, \exists r > 0\}$

$\{B(x, r) \mid x \in \text{aff } D\}$  一个点的  
D 的邻域包



、要求  $p^*$  及  $d^*$  在边缘 、 $\text{Relint } D$  即  $p^*$  包括边缘

Slater' 条件 ( $p^* = d^*$ )

充分但不要

若弱凸问题  $\min f(x)$  (凸)  
s.t.  $f_i(x)$  (凸)

Slater 条件  $\exists x \in \text{relint } D$ , 强对偶  
当  $\exists x \in \text{relint } D$ , 使  $f_i(x) \leq 0, Ax = b$ ,  
此时  $p^* = d^*$

(一个弱极的推论) 一般 linear 问题都满足 slater 条件

(弱) 弱 slater 条件  $Cx + d \leq 0$  且  $\exists x \in \text{relint } D$ ,  $Ax \leq b, Cx = d$

若以问题的强对偶是弱对偶约束, 此时只要  $x_f \neq 0$ ,  
则有  $p^* = d^*$

即  $p^* = d^*$  在弱对偶内解的上

是所有  $D$  的  $\cap$ , 但是可行域!

$$\text{relint } D = \text{relint} \{ \text{dom } f_0 \cap (\cap \text{dom } f_i) \}$$

检验 slater 条件

$$\text{relint } D = \text{relint} \{ \text{dom } f_0 \} \quad (\text{因为 } Ax + b \leq 0 \quad x \in R)$$

若  $\text{dom } f_0 = R$ , 则  $x_f \neq \emptyset$ , R 是 slater 集.

若  $\text{dom } f_0$  有内部, 则  $\text{relint } D \neq \emptyset \neq \emptyset$

例:  $f_0$  也仿射 (LP)

若  $d^* \neq \emptyset$ , 则  $d^* = p^*$

$$\begin{aligned} \text{例: } X^T X - s.t. \quad & Ax = b \\ & \therefore \text{若 } p^* = d^* \quad \text{则 } X_f \neq \emptyset \end{aligned}$$

例: QCQP

$$\min \frac{1}{2} X^T P_0 X + q_0^T X + r_0 \quad (P_0 \in S^n_{++})$$

$$s.t. \quad \frac{1}{2} X^T P_i X + q_i^T X + r_i \leq 0 \quad (P_i \in S^n_+)$$

$$P_0 \in S^n_{++} \quad P_i \in S^n_+$$

$$L(X, \lambda) = \frac{1}{2} X^T P_0 X + q_0^T X + r_0 + \sum_i \lambda_i \left( \frac{1}{2} X^T P_i X + q_i^T X + r_i \right)$$

$$g(\lambda) = \inf_{X \in D} L(X, \lambda) + \overbrace{\sum_i \lambda_i r_i}^{r_0}$$

$$\begin{aligned} &= \inf \left[ \underbrace{\frac{1}{2} X^T (P_0 + \sum_i \lambda_i P_i) X}_{Q(X)} + (q_0^T + \sum_i \lambda_i q_i^T)^T X \right. \\ &\quad \left. + (r_0 + \sum_i \lambda_i r_i) \right] \end{aligned}$$

$$(\lambda \geq 0) = -\frac{1}{2} Q^T(\lambda) P^{-1}(\lambda) Q(\lambda) + R(\lambda) \text{ 是 } \lambda \text{ 的凹函数}$$

↓  
检验 slater 条件

$$\textcircled{1} \quad X \in D \quad x \in R$$

不满足 slater, 但  $\exists d^* \in p^*$

$$\textcircled{2} \quad \frac{1}{2} X^T P_i X + q_i^T X + r_i \leq 0$$

$$\textcircled{2-1} \quad \text{若 } q_i^T r_i = 0, \quad \frac{1}{2} X^T P_i X \leq 0 \rightarrow$$

$$\textcircled{2-2} \quad \text{且 } s.t. \quad \frac{1}{2} X^T P_i X \leq 0, \quad X_f = \{0\}$$

$$p^* = \frac{r_0}{r_0}, \quad d^* = r_0, \quad p^* = d^*$$

S6

(2-2) 若  $g_i \neq 0, i \geq 0$ , 找对称解

32/55  $d^* = d^*$  的解集

几何解释


$$\min f(x)$$

$$\text{s.t. } f_i(x) \leq 0$$

$$G = \{(f_i(x), f_i(x)) \mid x \in D\}$$


则  $p^* = \inf \{t \mid (u, t) \in G, u \geq 0\}$

$$d^* g(x) = \inf \{\lambda u + t \mid (u, t) \in G\}$$



当  $G$  很奇怪时,  $p^* = d^*$  很困难.

当  $G$  规则时



的解

$$p^* = \boxed{L(x, \lambda), \inf_{x \in D} \sup_{\lambda \geq 0} L(x, \lambda)} = \boxed{\sup_{\lambda \geq 0} \inf_{x \in D} L(x, \lambda)} = d^*$$

若成立，称此问题有鞍点，对应的  $(\lambda^*, x^*)$  为鞍点  $L$  的

若左边 =  $p^*$ ，则

$$L = f_0(x) + \lambda f_i(x)$$

$$\sup L = f_0(x) + \sup(\lambda f_i(x))$$

① 若所有  $f_i(x) \leq 0$ ， $\sup L = f_0(x)$

② 若存在  $f_i > 0$ ， $\sup L = f_0(x) + \infty = +\infty$

$$\begin{aligned} \therefore \inf(\sup L) &\quad \because \text{只取 } ①, \text{ 即取 } f_0(x) \text{ 满足}, \inf(\sup L) \\ &\equiv \inf((f_0(x))) = \inf f_0(x) = p^* \end{aligned}$$

多目标优化角度的解

$\min \{f_0(x), \dots, f_m(x)\}$  是多目标，寻求最小的

通过引入  $\{i\}$   $\Rightarrow \min(f_0(x) + \sum_i f_i(x))$  即 Lagrangian function

解对偶问题

step ① 给定  $\lambda$ ， $\min_{x \in D} L(x, \lambda) \Rightarrow$  又为解

② 对入求极大  $\max_{\lambda \geq 0} g(\lambda) \rightarrow \bar{\lambda}$  为解

将  $\bar{\lambda}$  代入  $L(x, \lambda)$ ， $\min L(x, \bar{\lambda})$  为解与  $\min(f_0(x) + \sum_i \bar{\lambda}_i f_i(x))$  在  $d^* = p^*$  时等价

经济学解

$$\min f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0 \quad i=1, \dots, m$$

$x$  是商品数量， $f_0$  是正损失 ( $-f_0$  是利润)

$f_i(x)$  是第  $i$  种原材料的约束

若原材料叫约束

## 每个支撑点

若原材料可变卖，交易有收入；  
则最终损失为  $\min_{\lambda} (f_0(x) + \sum \lambda_i f_i(x)) = g(\lambda)$

剩下的材料：

若极小化损失，

即同时以不同的市场价格买入不同，故  $\min_{\lambda}$  是买入的函数

$\max_{\lambda}$  为最大损失  $= d^*$

弱对偶：  $\alpha^* \leq p^*$  (当原材料可变卖时，总损失一定 ≤ 可变卖时的总损失)

弱对偶说明市场经济比计划经济好

强对偶时  $\alpha^* = p^*$  只当资源配置非常好时

$x^*$  是生产计划，  $\alpha^*$  是市场价格调节，使市场价格总额最高  
(称为盈亏平衡)

33/55  $\rightarrow$  Boyd 书的线性知识，每个人讲的，自己找

34/55

35/55 路子价和  $\alpha^*$  的特点

$\alpha^* = 0$ , 则 剩下的材料 =  $f(x^*)$

$x^*$  时 对应的  $f_i(x^*) < 0$   $\alpha_i^* = 0$  (此时  $\alpha$  和支撑点一样)

即为最低

对应  $f_i(x^*) > 0$

当  $\alpha_i > 0$  , 则  $f_i(x^*)$  必无序有 = 0  
(市场价格)

且  $\alpha_i^* = 0$

剩余补充

$f(w, z), w \in S_w, z \in S_z$  (费用函数)

仅有  $\sup_z \inf_w f(w, z) \leq \inf_w \sup_z f(w, z)$

minimax 定理

想象  $f(w, z)$  为  $(w, z)$  位置的人的身高

$\sup(\inf)$  表示从一群矮子中找高的人

$\inf(\sup)$  表示从高个子中找一个最矮的

等式成立条件

① 等式成立 ② 所加的  $w, z$  也相等

称为等式  $(\bar{w}, \bar{z})$

等价定义,  $f(\bar{w}, \bar{z}) \leq f(\bar{w}, \bar{v}) \leq f(w, \bar{v})$  对  $\forall z, w$

$$L(x, \lambda) = f_0(x) + \sum \lambda_i f_i(x) \quad \begin{cases} \text{if } f_i(x) \leq 0, \text{ then } \sup \lambda = v; \text{ otherwise } +\infty \\ \text{if } x > 0 \end{cases}$$

$$\sup_{x>0} \{L(x, \lambda)\} = f_0(x) + \sup \{\sum \lambda_i f_i(x)\}$$

$$= f_0(x) \quad \begin{cases} \text{if } f_i(x) \geq 0 \text{ for all } i \\ \text{otherwise } +\infty \end{cases}$$

$$p^* = \min_x \{x | f_i(x) \leq 0 \forall i\}$$

$$= \inf_x \sup_{\lambda \geq 0} \{L(x, \lambda)\} \quad \text{即 } p^* = \max(p^*, \sup)$$

$$d^* = \max(\min_x L) = \sup_x \inf L$$

$$\text{且 } p^* \geq d^*$$

勒让德原理:

对只取等式约束的优化问题,  $(\bar{x}, \bar{z})$  为  $L(x, \lambda)$  的勒让德,

$\Leftrightarrow$  强对偶存在, 即  $\bar{x}, \bar{z}$  为  $d^*$  与  $p^*$  的最优解

$$p^* \geq d^*$$

$\Rightarrow$

• 勒:  $\sup \inf = \inf \sup \Rightarrow d^* = p^*$

都是基于勒让德意义

• 勒:  $(\bar{x}, \bar{z})$  既是左和右的最优解

$$(\bar{x}, \bar{z}) \Rightarrow = \arg \sup \inf L(x, \lambda)$$

$$\downarrow \lambda \quad x$$

$$\bar{z} = \arg \left[ \sup_{\lambda} \inf_x L(x, \lambda) \right] \quad \text{的对偶问题是 } g(\lambda) \text{ 的最优解}$$

对偶问题

$$\text{同理有 } (\bar{x}, \bar{z}) = \arg \inf \sup L(x, \lambda) \rightarrow \bar{x} \text{ 是 } f_0 \text{ primary 最优解}$$

60

← 證：

強弱偶存在  $\Rightarrow f_0(x^*) = g(\lambda^*)$

$\because x^*, \lambda^*$  分別為最值之

$\therefore x^*, \lambda^*$  皆可行解

$\therefore f_i(x^*) \leq 0, \forall \lambda^* \geq 0$

$$g(\lambda^*) = \inf_x \{f_0(x) + \sum \lambda^* f_i(x)\}$$

則 任  $x$ , 有  $f_0(x) \geq g(\lambda^*) \leq 0$

$$\begin{aligned} f_0(x^*) &= \inf_x \{f_0(x^*) + \sum \lambda^* f_i(x)\} \\ &= L(x^*, \lambda^*) \end{aligned}$$

∴ 每一步都滿意

36/55

用對偶問題的兩個意義

$$g(\lambda^*) = L(x^*, \lambda^*) \Rightarrow \inf_{\lambda \geq 0} L(x^*, \lambda^*) = L(x^*, \lambda^*)$$

再考慮  $\sup_{\lambda \geq 0} L(x^*, \lambda)$

$$= \sup_{\lambda \geq 0} \{f_0(x^*) + \sum \lambda f_i(x^*)\}$$

$$= \sup_{\lambda} f_0(x^*) + 0$$

$$= L(x^*, \lambda^*)$$

$$\left\{ \begin{array}{l} \inf_{\lambda} L(x^*, \lambda) = L(x^*, \lambda^*) \\ \sup_{\lambda} L(x^*, \lambda) = L(x^*, \lambda^*) \end{array} \right.$$

$\Rightarrow (x^*, \lambda^*)$  是弱光 (也是弱光另一個定義)

例： $\min f_0(x) \leftarrow$  第一層

s.t.  $f_i(x) \leq 0$

$h_i(x) = 0$

$$\text{對偶函數 } g(x) = \inf_x \{f_0(x) + \sum \lambda^* f_i(x) + \sum \nu h_i(x)\}$$

对偶问题:  $\max g(\lambda, v)$

s.t.  $\lambda \geq 0$

(做两个假设: ①  $d^* = p^*$   $\rightarrow$  此时有许多好性质)

② 所有  $f_i, h_i$  可微)

设此时已找到  $(x^*, \lambda^*, v^*)$

有 ③  $f_i(x^*) \leq 0 \quad i \geq 1$

④  $h_i(x^*) = 0$

①  $\lambda^* \geq 0$

$$f_0(x^*) = g(\lambda^*, v^*) \quad (\because p^* = d^*)$$

$$= \inf_x \{ f_0(x) + \sum \lambda_i^* f_i(x) + \sum v_i^* h_i(x) \} = \inf_x L(x, \lambda^*, v^*)$$

变成等号  $\left\{ \begin{array}{l} \leq f_0(x^*) + \sum \lambda_i^* f_i(x^*) + \sum v_i^* h_i(x^*) \\ \geq f_0(x^*) \end{array} \right. \leq 0 \quad \therefore L(x^*, \lambda^*, v^*)$

$\therefore$  式成立

$$\therefore \sum \lambda_i^* f_i(x^*) = 0$$

$$\therefore \forall \lambda_i^* f_i(x^*) \leq 0$$

$$\therefore \forall \lambda_i^* f_i(x^*) = 0$$

① 若  $\lambda_i^* > 0 \Rightarrow f_i(x^*) = 0$  (价格 > 0  $\rightarrow$  无剩余)

② 若  $f_i(x^*) < 0 \Rightarrow \lambda_i^* = 0$  (有剩余  $\rightarrow$  价格 = 0)

① 互补松弛条件 Complementary slackness

(含意, " $\leq$ " 一个 " $\leq$ " 可由另一个 " $=$ " 仍存在变成 " $<$ ")

$$\frac{\partial L(x, \lambda^*, v^*)}{\partial x} |_{x=x^*} = 0$$

②

稳定性  
stationarity

$$\nabla f_0(x^*) + \sum \lambda_i^* \nabla f_i(x^*) + \sum v_i^* \nabla h_i(x^*) = 0$$

$(\lambda^*, v^*)$  是稳定

共 5 个式子, 可否为中等

一、原问题的可行性 ③ ④

二、对偶问题可行性 ⑤ KKT 条件

三、互补松弛 ①

四、稳定性 ②

62

KKT条件，是最优解的必要条件

(充要时充分)

若原问题为凸问题，各个函数可微，对偶间隙为0，则KKT为充要条件

加上了凸问题的条件

给凸问题时充要：

若凸物泛函  $L(x, \bar{x}, \bar{v})$  满足 KKT 条件，则这有  $(\bar{x}, \bar{v})$  为最优解

$$\text{即 } g(\bar{x}, \bar{v}) = f_0(\bar{x})$$

(因为由 KKT 条件  $(\bar{x}, \bar{v})$  为鞍点(极大=极小点))

鞍点

$$\therefore g(\bar{x}, \bar{v}) = f_0(\bar{x}) \quad (\text{间隙为0})$$

$(\bar{x}, \bar{v})$  为最优解

先用 KKT 的 5 个条件

$$f_i(\bar{x}) \leq 0$$

$$h_i(\bar{x}) = 0$$

$$\lambda_i \geq 0, \rightarrow L(\bar{x}, \bar{\lambda}, \bar{v})$$

$$= f_0(\bar{x}) + \sum_i \lambda_i f_i(\bar{x}) + \sum_i \bar{v}_i h_i(\bar{x})$$

凸问题

$$\because h_i \text{ 为凸 } \rightarrow \sum_i \bar{v}_i h_i(\bar{x}) \geq f_i(\bar{x})$$

非负加权

∴ L 为凸数

$\forall i \geq 0$  得最优解

$$g(\bar{x}, \bar{v}) = \inf_{x \in D} L(x, \bar{\lambda}, \bar{v})$$

$$= L(\bar{x}, \bar{\lambda}, \bar{v})$$

$$= f_0(\bar{x}) + \left( \sum_i \lambda_i f_i(\bar{x}) \right) + \left( \sum_i \bar{v}_i h_i(\bar{x}) \right)$$

即互补松弛

$$g(\tilde{x}, \tilde{v}) = f_0(\tilde{x}) \text{ 括号得证}$$

(通过 KKT 中的互补松弛和对偶问题的可行性)

KKT 的意义在于：求解 KKT 等价于求解原问题 (凸优化问题)

① 为 KKT  
充要

$\Leftrightarrow d^* = p^*$  (注意，凸问题只有满足 slater 条件才  $d^* = p^*$ )

所有函数都可微的优化问题

凸问题

例 3.1.2  $\min \frac{1}{2} \mathbf{x}^\top P \mathbf{x} + \mathbf{q}^\top \mathbf{x} + r$        $P \in \mathbb{S}_+^n$   
 s.t.  $A\mathbf{x} = b$

写出 KKT: ①  $A\mathbf{x}^* = b$

②  $\lambda_i \geq 0$  且需等

③ 互补松弛

④  $\nabla f_0 = P\mathbf{x}^* + Q + A^\top \lambda^* = 0$

$$\begin{bmatrix} P & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \mathbf{x}^* \\ \lambda^* \end{bmatrix} = \begin{bmatrix} -Q \\ b \end{bmatrix} \text{ 可求解}$$

(当  $A\mathbf{x} \geq b$  时，很简单，因为 ③ )

Water-filling 灌水算法:  $\rightarrow$  信道能量

$$\min -\sum_i^n \log(1 + \alpha_i x_i) \quad \text{凸问题}$$

s.t.  $x \geq 0, \mathbf{1}^\top x = 1$

写出 KKT: ①  $x \geq 0$

②  $\mathbf{1}^\top x^* = 1$

③  $\lambda^* \geq 0$  ( $-\lambda^* \leq 0$ )

④  $\lambda^* x_i = 0$

$$\textcircled{5} \quad \frac{1}{x_i + x_i^*} - \lambda_i^* + v_i^* = 0$$

$$\textcircled{3} \Rightarrow \lambda_i^* = v_i^* - \frac{1}{x_i + x_i^*} \text{ 代入 } \textcircled{2}, \textcircled{3}, \textcircled{4}$$

64

$$(4) x_i^* \left( v_i^* - \frac{1}{\alpha_i + x_i^*} \right) = 0 \quad (\text{到这里, ② 说明情况3})$$

$$(3) v_i^* \geq \frac{1}{\alpha_i + x_i^*} \Rightarrow$$

Case 1: 若  $v_i^* \geq \frac{1}{\alpha_i}$ ,

$$\text{代入 (4)} \quad x_i^* = 0$$

case 2: 若  $v_i^* < \frac{1}{\alpha_i}$ ,  $(x_i^* > \frac{1}{\alpha_i}, \alpha_i > \frac{1}{v_i^*}) \quad \left. \begin{array}{l} \text{到这里, (3)(4)} \\ \text{消掉成一条} \end{array} \right\}$


代入 (3)

$$\frac{1}{\alpha_i + x_i^*} < \frac{1}{\alpha_i} \Rightarrow x_i^* > 0, x_i > 0$$

$$\therefore v_i^* - \frac{1}{\alpha_i + x_i^*} = 0$$

$$x_i^* = \frac{1}{v_i^*} - \alpha_i$$


$\downarrow$



$i$  (不同的顺序)

在 case 1 中

若  $\frac{1}{v_i^*}, \alpha_i$



case 1

灌水事件,


① 要灌的水位比原来低, 灌了进去

第二步灌水

②

高, 灌到  $\frac{1}{v_i^*}$

第二步灌水



$x_i$  是每个池子的高

$$x_i \geq 0 \quad \checkmark$$

$$\sum x_i = 1$$

(灌水会使  $x_i$  变差)

$$x_1 = x_j$$

KKT 与凸函数 - 所谓对偶

$$\text{例: } \min f_0(x) \text{ 凸}$$

$$\text{s.t. } x \geq 0$$

$$\Rightarrow x \geq 0,$$

$$\begin{aligned} \text{这是这个问题是} & \left\{ \begin{array}{l} \nabla f_0(x) \geq 0 \\ x_i (\nabla f_0(x)) = 0 \end{array} \right. \rightarrow \text{所求最低限条件} \\ \text{的最优化} & \uparrow \text{(互补)} \\ \text{条件} & \downarrow \text{本质相同} \end{aligned}$$

和 KKT 的互补松弛

KKT 条件: (充要)

$$x^* \geq 0, \lambda^* \geq 0, \lambda_i x^* = 0, \nabla f_0(x^*) + (-\lambda^*) = 0$$

例:  $f_0(Ax+b)$

$$L(x) = f_0(Ax+b) \quad g(v) = \inf_x f_0(Ax+b) \quad (\max g) \text{ 对偶问题}$$

↓ 变形

$$\min f_0(y)$$

$$\text{s.t. } Ax+b=y$$

$$L(x, y, v) = f_0(y) + v(Ax-y+b)$$

$$= f_0(y) - v^T y + v^T A x + v^T b$$

$$g(v) = \inf_{x, y} L = \inf_x \inf_y L \quad (\text{因为 } x \perp y)$$

$$= \inf_x (-f_0^*(v)) + \cancel{v^T A x}$$

or -

$$= -f_0^*(v) + 0 + v^T b$$

$$\text{对偶问题为 } \max(g(v)) = \max(-f_0^*(v) + v^T b)$$

~~说明同一个问题~~

说明同一个问题变化后, 对偶问题也会变